

引用格式: 刘杰,张彤,王培晓,等. 基于卡尔曼“估计-校正”循环网络的暴雨临近预测[J]. 地球信息科学学报,2025,27(4):888-899. [Liu J, Zhang T, Wang P X, et al. Rainstorm nowcasting using Kalman "Estimation-Correction" recurrent network[J]. Journal of Geo-information Science, 2025,27(4):888-899.] DOI:10.12082/dqxxkx.2025.240452; CSTR:32074.14.dqxxkx.2025.240452

基于卡尔曼“估计-校正”循环网络的暴雨临近预测

刘 杰¹, 张 彤^{2*}, 王培晓³, 韩士元⁴, 冷 亮⁵, 肖艳姣⁵

1. 济南大学信息科学与工程学院, 济南 250022; 2. 武汉大学 测绘遥感信息工程国家重点实验室, 武汉 430079; 3. 中国科学院地理科学与资源研究所 地理信息科学与技术全国重点实验室, 北京 100101; 4. 山东女子学院人工智能学院, 济南 250300; 5. 中国气象局武汉暴雨研究所 中国气象局流域强降水重点开放实验室/暴雨监测预警湖北省重点实验室, 武汉 430205

Rainstorm Nowcasting Using Kalman "Estimation-Correction" Recurrent Network

LIU Jie¹, ZHANG Tong^{2*}, WANG Peixiao³, HAN Shiyuan⁴, LENG Liang⁵, XIAO Yanjiao⁵

1. School of Information Science and Engineering, University of Jinan, Jinan 250022, China; 2. State Key Laboratory of Information Engineering in Surveying, Mapping and Remote Sensing, Wuhan University, Wuhan 430079, China; 3. State Key Laboratory of Resources and Environmental Information System, Institute of Geographic Sciences and Natural Resources Research, Chinese Academy of Sciences, Beijing 100101, China; 4. School of Artificial Intelligence, Shandong Women's University, Jinan 250300, China; 5. China Meteorological Administration Basin Heavy Rainfall Key Laboratory/Hubei Key Laboratory for Heavy Rain Monitoring and Warning Research, Institute of Heavy Rain, China Meteorological Administration, Wuhan 430205, China

Abstract: [Objectives] Accurate rainstorm prediction plays an important role in disaster prevention and mitigation, industrial and agricultural production, and transportation, making it crucial for safeguarding social and economic development as well as people's property. However, existing intelligent rainstorm prediction methods fail to fully account for the uncertainties inherent in the rainstorm process itself, as well as in observation and modelling, which limits the improvement of prediction accuracy and stability. **[Methods]** To address this issue, an "estimation-correction" recurrent network based on filtering theory is proposed. This network estimates the meteorological state with the constraints of substantial derivative and corrects the state according to estimation errors, enabling accurate and reliable rainstorm prediction. The "estimation-correction" network consists of two main units, the state estimation unit and the state correction unit. Constrained by substantial derivative, the state estimation unit estimates the meteorological state and error for the next time step based on historical meteorological states. Guided by estimation error, the state correction unit corrects meteorological state by

收稿日期:2024-08-16;修回日期:2024-11-04.

基金项目:湖北省技术创新计划重点研发专项项目(2023BCB119);湖北省自然科学基金(创新发展联合基金)(2022CFD012);山东省自然科学基金项目(ZR2024QD179、ZR2020KF006);国家自然科学基金项目(42401524、62373164);中国气象局气象能力提升联合研究专项(22NLTSY015)。[**Foundation items:** Hubei Province Key R&D Plan Project, No.2023BCB119; Hubei Provincial Natural Science Foundation of China, No.2022CFD012; National Natural Science Foundation of Shandong Province, No.ZR2024QD179, No.ZR2020KF006; National Natural Science Foundation of China, No.42401524, No.62373164; The Joint Research Program for Enhancing Meteorological Capabilities by the China Meteorological Administration, No.22NLTSY015.]

作者简介:刘 杰(1995—),女,山东济南人,博士,主要从事时空预测研究。E-mail: ise_liuj@ujn.edu.cn

*通讯作者:张 彤(1979—),男,福建武夷山人,教授,主要从事时空机器学习、高分遥感解译、交通地理信息系统研究。
E-mail: zhangt@whu.edu.cn

fusing estimation and observation errors. The two units work together to enhance prediction accuracy and stability. **[Results]** Experiments conducted on the ERA5 and NCEP reanalysis datasets demonstrate that the proposed method improves the Critical Success Index (CSI) of rainstorm prediction by 5% compared to other methods. Furthermore, it achieves good stability, as indicated by a stability metric ($SPREAD \approx 0.5$). **[Conclusions]** These results validate the feasibility of integrating filtering theory with deep learning to address uncertainty in rainstorm prediction.

Key words: rainstorm prediction; Kalman filtering; "Estimation-Correction" recurrent network; substantial derivative; physics-informed neural network

***Corresponding author:** ZHANG Tong, E-mail: zhangt@whu.edu.cn

摘要:【目的】精确的暴雨临近预测在防灾减灾、工农业生产和交通运输等多方面起着重要作用,对于保障社会经济发展与人民财产安全具有十分重要的意义。然而现有暴雨智能预测方法没有充分考虑暴雨过程、观测以及建模等环节的不确定性问题,阻碍了预测准确性和稳定性的提升。【方法】本文提出基于卡尔曼“估计-校正”循环网络的暴雨临近预测方法,在个别变化理论约束下估计气象状态,并在卡尔曼滤波的指导下依据估计误差进行气象状态校正,以实现准确和可靠的暴雨预测。所提“估计-校正”网络包括个别变化约束的深度状态估计和估计误差指导的气象状态校正2个核心单元;前者根据历史气象状态估计下一时间步的气象状态及误差;后者根据估计误差和观测误差进行气象状态的校正;二者共同提升暴雨预测精度和稳定性。【结果】在ERA5和NCEP数据集上的实验证明,所提方法的暴雨预测准确性指标CSI比所对比的基线方法提升了5%,并以稳定性指标 $SPREAD \approx 0.5$ 的成绩取得了良好稳定性。【结论】验证了在深度学习中融合滤波理论缓解不确定性问题可行性。

关键词:暴雨预测;卡尔曼滤波;“估计-校正”循环网络;个别变化;物理信息神经网络

1 引言

暴雨不仅危害农作物生长与收获^[1],还可能引发洪涝灾害及地质灾害,给工农业生产、人民生命财产和城市发展带来巨大威胁。以2021年7月郑州暴雨事件为例,该事件导致292人死亡,超过10万 ha^2 农作物受灾,造成直接经济损失532亿元^[2]。提高暴雨预测水平,能够为防灾减灾提供风险信息与决策性建议,减少暴雨对工农业、运输、基础建设等多方面的负面影响,对于保障社会经济发展与人民财产安全具有十分重要的意义。

传统数值预报方法在面对短临暴雨预测任务时,仍然存在模型运转耗时、计算成本高、物理参数化方案难以真正模拟实际混沌过程等多种问题,往往不能提供精准的临近预报^[3-5]。相比之下,数据驱动的机器学习方法具有拟合高维非线性样本和构建预测模型的强大能力^[6],已在天气预报实践中展现出了巨大的潜力^[7-8],成为缓解大气不确定性问题的有效的工具^[9]。尽管现在有部分深度学习模型考虑到了暴雨预测中的时空关联和样本不平衡等问题^[10-13],但由于深度学习方法的黑盒子特性,上述方法并不一定遵守物理系统的基本定律。因此,深度学习驱动的气象预报研究已经开始在深度学习模型中融入物理先验知识并取得了显著进

展^[14-16],如以平流守恒定律为物理条件的生成性极端降水预测模型^[17]。

然而,上述预测方法没有充分考虑大气过程、观测和深度模型建模等各个环节中的不确定性问题。在不确定性因素的影响下,数据或者模型的微小偏差可能会导致预测结果的巨大差异,这阻碍了暴雨预测准确性和鲁棒性的进一步提升。传统数值气象预报采用集合预报方法来缓解不确定性问题,即在不同初始条件、参数设置或模型配置下对大气进行多次物理模拟。为了降低集合预报的时间和计算成本,研究人员开始利用深度学习模型生成集合成员^[18-19],例如,在输入数据或高层特征上添加随机高斯噪音^[19-20],或利用扩散模型的加噪-去噪过程^[21,18]模拟不确定性。但这种基于深度学习模型的集合预测方法存在2个问题:①相较于单一确定性预测模型,集合预测方法耗费时间和计算成本;②上述基于深度学习的集合生成的方式仅单一模拟大气或预测模型的不确定性,没有综合考虑大气和建模等环节的不确定性。

针对上述问题,本文提出基于滤波理论的卡尔曼“估计-校正”循环网络(Kalman Estimation-Correction Network, KalECNet)的暴雨临近预测方法,在深度学习模型中显式集成卡尔曼滤波理论和个别变化方程,通过误差估计与校正机制提高暴雨预

测的精度和可信度。所提网络包括2个主要单元：个别变化约束的气象状态估计单元和估计误差指导的气象状态校正单元。前者在个别变化约束下，建立深度气象状态空间方程，根据历史气象状态和误差，估计未来的气象状态和误差；后者在卡尔曼滤波理论的指导下，通过过程误差、估计误差和观测误差计算校正权重，实现基于误差的气象状态校正。本文的主要创新体现在根据卡尔曼滤波建立的误差估计与校正机制和个别变化方程对深度学习模型的物理约束。

2 研究方法

2.1 问题定义与整体框架

针对暴雨大气和建模等环节存在的不确定性，本文提出卡尔曼“估计-校正”循环网络在一个模型中同时完成暴雨预测和误差校正，缓解预测中的不确定性，提高暴雨预测精度和稳定性。

本文形式化定义暴雨时空过程预测问题如下：

$$\hat{R}_{t+1}, \dots, \hat{R}_{t+h} = F(R_{t-m+1}, \dots, R_t; Y_{t-m+1}, \dots, Y_t) \quad (1)$$

式中：研究区域被划分成 $n_w \times n_h$ 的网格。 $\hat{R}_{t+1}, \dots, \hat{R}_{t+h} \in \mathbb{R}^{n_w \times n_h}$ 表示预测的研究区域内所有网格的未来 h 步的降水量， R_{t-m+1}, \dots, R_t 表示研究

区域内所有网格在过去 m 步的降水量， Y_{t-m+1}, \dots, Y_t 表示研究区域内所有网格在过去 m 步的大气属性数据。大气属性数据包含对暴雨预测至关重要的典型气象变量的信息，如气温、气压、湿度和风速，也包括了降水量。在式(1)中重复降水量是为了强调本文将过去的降水量作为输入，而不是仅仅采用温压湿风等大气属性。 $F(\cdot)$ 是一个数据驱动的暴雨预测函数，旨在充分捕获暴雨的时空动态和依赖性。

图1说明了卡尔曼“估计-校正”循环网络的整体流程。整个方法循环“估计-校正”2个环节，通过对气象状态的估计与校正完成暴雨预测。具体计算步骤为：① 状态编码：将 t 时刻实际气象观测值输入编码网络，获得嵌入观测状态；② 状态估计：基于上一时刻($t-1$ 时刻)的气象状态，估计 t 时刻气象状态；③ 状态校正：依据 t 时刻嵌入观测状态校正 t 时刻估计状态；④ 状态解码：将 t 时刻校正的气象状态输入解码网络，转换为 t 时刻降水量值，完成对 t 时刻的暴雨预测。在实际预测过程中 t 时刻的嵌入观测状态是未知的，初始化为全0矩阵。上述步骤的第①步和第④步对应了图1中的编解码过程，第②步和第③步分别对应了方法的2个核心单元。

(1) 个别变化约束的气象状态估计。估计单元使用基于个别变化的深度状态方程估计气象状态

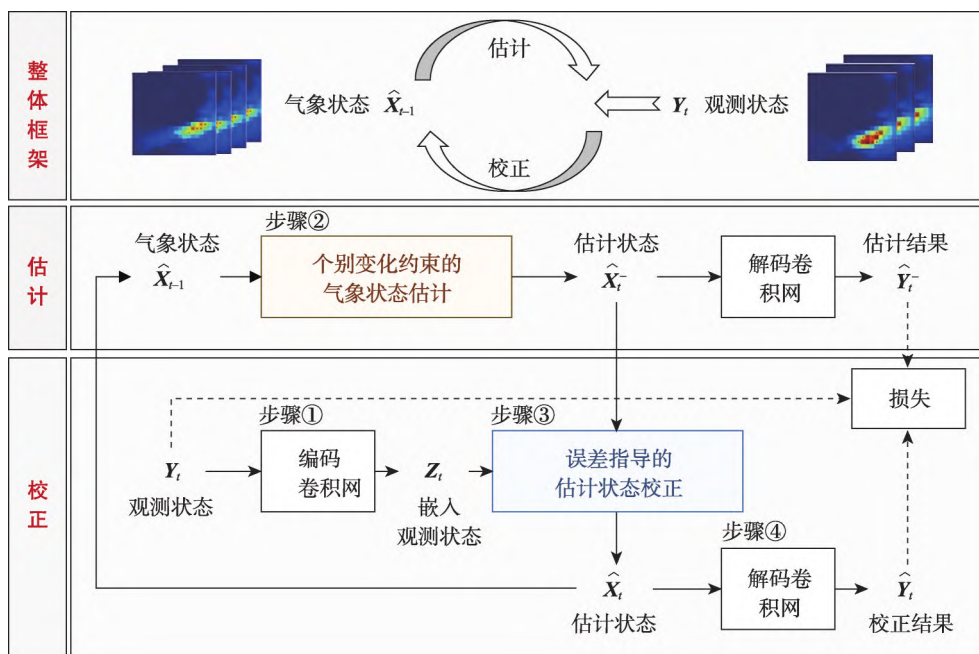


图1 基于卡尔曼“估计-校正”循环网络的暴雨临近预测框架

Fig. 1 The framework of rainstorm prediction using Kalman "estimation-correction" recurrent network

和估计误差。估计单元将会在个别变化理论的指导下,根据历史气象状态计算由当前状态变化到下一时间步状态的状态转移矩阵,然后基于状态转移矩阵和当前状态实现对下一时间步状态以及误差的估计。估计状态可以通过解码网络转换为估计降水量。

(2)误差指导的气象状态校正。校正单元会使用基于观测与估计误差的卡尔曼增益校正估计单元的估计结果。校正单元首先会由估计误差和观测噪声计算卡尔曼增益,判断应该更加信任实际观测状态还是估计状态,然后将卡尔曼增益作为融合权重融合实际观测状态和估计状态,实现基于误差的状态校正。气象状态校正完毕之后,可以用解码网络将气象状态转换为降水量值,完成暴雨预测。

本文采用加权求和的方式将估计单元的估计降水量和校正单元的预测降水量的均方误差(MSE)损失及时空一致约束损失联合为总损失,端对端训练所提卡尔曼“估计-校正”网络。

2.2 个别变化约束的气象状态估计

在应用卡尔曼滤波相关理论时,首要步骤是建立状态空间方程与观测方程,这两者是构筑“估计-校正”循环过程的基础,其中状态方程描述系统状态的动态演变过程,观测方程表达系统状态与观测数据之间的关系。

为了提高预测模型建模大气动态变化以及暴雨时空关联的能力,本文根据描述大气运动时空变化的个别变化,设计气象状态方程,形成了基于个别变化的深度状态方程。如式(2)所示,个别变化表达式^[22]描述了大气运动的时空变化规律,可以推广应用至包括压力,温度和速度分量在内的多种物理量的描述中。

$$\frac{dX}{dt} = u \frac{\partial X}{\partial x} + v \frac{\partial X}{\partial y} + w \frac{\partial X}{\partial z} + \frac{\partial X}{\partial t} \quad (2)$$

式中: X 表示流体微元的某一物理量; u, v 和 w 分别为流体微元在 x, y, z 3个方向上的移动速度; t 表示时间。 dX/dt 表示个别变化,为运动过程中微元所具有的物理量随时间的变化率。 $\partial X/\partial t$ 表示局地变化,是固定在流场中的某一位置来观测到的物理量的时间变化率。一般 $u \frac{\partial X}{\partial x} + v \frac{\partial X}{\partial y} + w \frac{\partial X}{\partial z}$ 表示平

流变化,是由于物理量空间分布不均匀而引起的物理量变化。

为了将个别变化结合到状态方程中,本文对公式(2)个别变化进行变换。首先,暴雨预测的实现应该关注局地变化和平流变化,因此个别变化和对流变化项直接合并为残差项 S 。残差 S 也可以考虑到物理公式无法完全解释实际现象的问题。其次,本文将局地变化 $\partial X/\partial t$ 简化为2个相连时间步的状态之差 $X_t - X_{t-1}$,其中 $X_t \in \mathbb{R}^{n_x \times n_y \times n_z \times c_x}$ 。类似地,将平流变化中的 $\partial X/\partial x$ 和 $\partial X/\partial y$ 简化为 X_{t-1} 上格网点与 x, y 方向上相邻格网点的物理量的梯度差 $gd_x(X_{t-1})$ 和 $gd_y(X_{t-1})$ 。基于上述简化,可以推导出气象状态方程为。

$$X_t = X_{t-1} - U_{t-1} \circ gd_x(X_{t-1}) - V_{t-1} \circ gd_y(X_{t-1}) - S_{t-1} + W \quad (3)$$

式中: X_t 表示 t 时气象状态; $U_{t-1}, V_{t-1}, S_{t-1} = \text{ConvGRUs}(X_{t-m+1}, \dots, X_{t-1})$ 都是根据历史状态学习到的状态转移矩阵; $\text{ConvGRUs}()$ 为卷积门控循环网络; \circ 为哈达玛积操作; W 为过程噪声,此处假设过程噪声随系统状态变化而变化。在实际估计的时候,无法得知过程噪声 W ,且应考虑到暴雨的时空非线性特点,因此,估计单元实际求得的估计状态为。

$$\hat{X}_t = \iota(\hat{X}_{t-1} - U_{t-1} \circ gd_x(\hat{X}_{t-1}) - V_{t-1} \circ gd_y(\hat{X}_{t-1}) - S_{t-1}) \quad (4)$$

式中: \hat{X}_{t-1} 为上一步经过“估计-校正”的校正状态; \hat{X}_t 为基于 $t-1$ 时校正状态 \hat{X}_{t-1} 推算而得的估计状态; $\iota(\cdot)$ 为LeakyRelu激活函数。

图2说明了个别变化约束的气象状态估计的流程。如图2(a)所示,估计单元的输入为历史气象状态 $X_{t-m+1}, \dots, X_{t-1}$,输出的是基于物理先验(即个别变化)所估计的下一步的气象状态 X_t 。气象状态估计单元首先将历史气象状态 $X_{t-m+1}, \dots, X_{t-1}$ 输入到卷积门控循环网络中,求出了气象状态在空间 x, y 方向的移动位移 U_{t-1}, V_{t-1} 和残差 S_{t-1} 等状态转移矩阵。第(2)步,计算上一步的气象状态 X_{t-1} 在空间 x, y 方向的梯度变化 $gd_x(X_{t-1}), gd_y(X_{t-1})$ 。第(3)步,基于个别变化所描述的气象状态之间的关系,根据式(4),估计下一时间步的气象状态 X_t 。图2(b)展示了气象状态估计单元中所用卷积循环网络的结构。

在构建基于卡尔曼滤波框架的“估计-校正”循环之前,还须建立观测方程。为了能够快速、准确

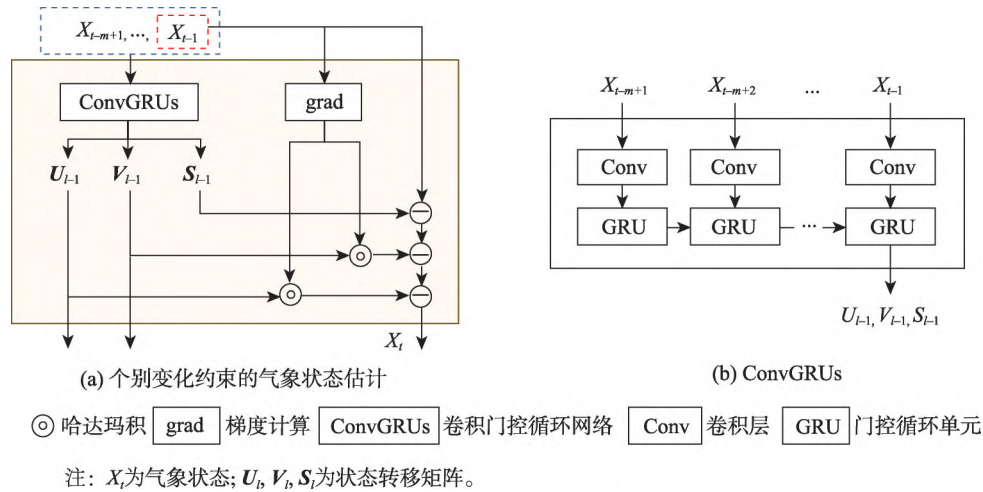


图2 个别变化约束的气象状态估计

Fig. 2 The estimation of meteorological state constrained by substantial derivative

地建立起观测值和估计值之间的关系,本文首先将观测值 Y_t 的属性及空间特征嵌入为高维特征 Z_t , 然后直接采用单位矩阵 I 作为观测矩阵,即:

$$Z_t = HX_t + F \quad (5)$$

式中:观测矩阵 $H=I$; F 为观测噪声,此处假设观测噪声随系统状态变化而变化。

$$Z_t = \text{En_Convs}(Y_t) \quad (6)$$

式中: Z_t 是观测值 Y_t 的嵌入结果,本文用其替代 Y_t 成为卡尔曼“估计-校正”网络中的“观测状态”,在后文称之为嵌入观测状态。在使用嵌入观测状态进行卡尔曼优化时,所得结果为对嵌入观测状态的最优估计,需要建立解码网络将嵌入观测状态转换为观测值。因此,在卡尔曼“估计-校正”网络中,还需要建立 $Y_t = \text{De_Convs}(Z_t)$ 的解码网络来得到最终的暴雨预测结果。

至此,可以根据式(3)和式(5),建立气象系统状态方程与观测方程为:

$$\begin{cases} X_t = X_{t-1} - U_{t-1} \circ \text{gd}_x(X_{t-1}) - V_{t-1} \circ \text{gd}_y(X_{t-1}) - S_{t-1} + W \\ Z_t = HX_t + F \end{cases} \quad (7)$$

式中: U_{t-1} 、 V_{t-1} 、 S_{t-1} 为状态转移矩阵; \circ 为哈达玛积操作;观测矩阵 $H=I$; W 和 F 分别为过程噪声和观测噪声。 Z_t 是观测值的嵌入结果,即嵌入观测状态,可以通过解码得到预测值 Y_t 。

2.3 估计误差指导的气象状态校正

受卡尔曼滤波器的“估计-校正”思路启发,本

文用嵌入观测状态 Z_t 校正估计状态 \hat{X}_t^- , 得到校正状态 \hat{X}_t , 并校正估计误差 E_t^- 得到校正误差 E_{t-1} , 这一过程通过以下公式实现:

$$\begin{cases} \hat{X}_t = \hat{X}_t^- + K_t (Z_t - H_t \hat{X}_t^-) \\ E_{t-1} = (I - K_t H_t) E_t^- \end{cases} \quad (8)$$

式中: $K_t \in \mathbb{R}^{n_v \times n_b \times c_x}$ 为卡尔曼增益,能够依据估计误差和观测误差,合理融合估计状态和观测状态。本文将卡尔曼增益 K_t 理解为估计状态和观测状态融合的权重,当卡尔曼增益 K_t 较大时,意味着观测值较为可靠,校正过程中应该融合更多观测值;反之,当卡尔曼增益 K_t 较小时,意味着估计值比较可靠,校正过程中应该保留更多估计值。 H_t 为观测矩阵, I 为单位矩阵。值得注意的是,在本阶段观测噪声不明确,因此没有体现在公式中。

本文估计的目标为:根据状态估计(式(4))和校正(式(8)),找到最优估计 \hat{X}_t , 使得损失(误差)最小。此过程中,卡尔曼增益 K_t 为关键未知变量,可以通过卷积网络学习获得。如式(9)所示,本文采用卷积网络从估计状态误差 E_t^- 和观测噪声 F_t 中学习卡尔曼增益 K_t , 基于上一时间步校正状态误差 E_{t-1} 和过程噪声 W_t 计算估计状态误差。

$$\begin{cases} E_t^- = \iota(E_{t-1} - U_{t-1} \circ \text{gd}_x(E_{t-1}) - V_{t-1} \circ \text{gd}_y(E_{t-1}) + W_t) \\ K_t = \sigma(\text{conv}(E_t^- - F_t)) \end{cases} \quad (9)$$

式中: $\text{conv}(\cdot)$ 为卷积操作; $\iota(\cdot)$ 为 LeakyRelu 激活函数; $\sigma(\cdot)$ 为 Sigmoid 激活函数。 U_{t-1} 、 V_{t-1} 为状态

转移矩阵。式(9)基于上一时间步校正状态误差 E_{t-1} 和过程噪声 W_t 更新估计误差,第二个公式基于估计状态误差 E_t^- 和观测噪声 F_t 计算卡尔曼增益。过程噪声 W_t 可以在使用状态估计(式(4))计算估计状态 \hat{X}_t^- 时采用相同的方式一并计算,同理,观测噪声 F_t 可以在使用观测嵌入式(6)计算观测状态 Z_t 时一并计算。由此可见,卡尔曼增益 K_t 考虑到了大气过程、观测和估计等多个环节的不确定性。

获得卡尔曼增益 K_t 后,通过状态校正(式(8))和卡尔曼增益计算(式(9))可以获得校正后的状态估计 \hat{X}_t 和误差估计 E_{t-1} 。随后将待预测时间步输出的校正状态 \hat{X}_t 带入到观测方程式(5)中,即可得到对应嵌入观测状态 \hat{Z}_t ,解码嵌入观测状态可得到预测降水量 \hat{R}_t 。上述过程可以公式化为:

$$\begin{cases} \hat{Z}_t = H\hat{X}_t \\ \hat{R}_t = \text{De_Convs}(\hat{Z}_t) \end{cases} \quad (10)$$

式中:取观测矩阵 H 为单位阵,因为观测状态已被编码器映射至估计状态所在状态空间中。在预测未来 h 时间步的暴雨时,待预测 h 步的观测状态未知时,会将待预测时间步的嵌入观测状态置0以完成整个“估计-校正”过程。

2.4 卡尔曼“估计-校正”网络

卡尔曼“估计-校正”网络的计算过程实质上是对非线性气象系统状态进行循环估计的过程。卡尔曼“估计-校正”网络的关键步骤可以按顺序总结为5个核心公式:

估计状态:

$$\hat{X}_t^-, W_t = \iota \left(\hat{X}_{t-1} - U_{t-1} \circ \text{gd}_x(\hat{X}_{t-1}) - V_{t-1} \circ \text{gd}_y(\hat{X}_{t-1}) - S_{t-1} \right) \quad (11)$$

估计误差:

$$E_t^- = \iota \left(E_{t-1} - U_{t-1} \circ \text{gd}_x(E_{t-1}) - V_{t-1} \circ \text{gd}_y(E_{t-1}) + W_t \right) \quad (12)$$

卡尔曼增益:

$$K_t = \sigma \left(\text{conv}([E_t^- - F_t]) \right) \quad (13)$$

校正状态:

$$\hat{X}_t = \hat{X}_t^- + K_t(Z_t - H\hat{X}_t^-) \quad (14)$$

校正误差:

$$E_{t-1} = (I - K_t H) E_t^- \quad (15)$$

式中: Y_t 表示 t 步的 k 维大气属性数据; Z_t 是大气属性数据的嵌入结果(作观测状态用); F_t 表示观测噪声; \hat{X}_t^- 表示估计状态; W_t 表示过程噪声; $U_{t-1}, V_{t-1}, S_{t-1}$ 都是根据历史状态学习到的状态转移矩阵; E_t^- 为估计误差; K_t 卡尔曼增益; \hat{X}_t 为校正状态; E_{t-1} 为校正误差, H 为观测矩阵; \hat{R}_t 表示预测降水量。当 $t=1$ 时,初始化气象状态 \hat{X}_0 和估计误差 E_0 分别为输入的 m 小时的观测状态的均值和标准差。

如式(11)一式(15)所示,在估计阶段,该网络依据历史气象状态,在个别变化的约束下,估计下一时间步的气象状态 \hat{X}_t^- (对应式(11)),估计当前状态的误差 E_t^- (对应式(12))。在校正阶段,先根据观测噪声 F_t 、过程噪声 W_t 和估计误差 E_t^- ,计算卡尔曼增益(对应式(13)),在这一步中可以考虑到大气过程、观测和估计等多个环节的不确定性。卡尔曼增益可以理解为估计状态和观测状态的组合权重,观测噪声 F_t 越大,卡尔曼增益越小,状态校正时 KalECNet 会更信任估计状态,估计状态所占权重大,观测状态所占权重小;估计误差 E_t^- 越大,卡尔曼增益越大,状态校正时 KalECNet 会更信任观测状态,估计状态所占权重小,观测状态所占权重大。最后,根据卡尔曼增益对估计状态和估计误差进行校正(对应式(14)和式(15)),完成整个“估计-校正”过程。整个卡尔曼“估计-校正”网络的计算过程就是不断迭代估计和校正2个环节的过程。

2.5 损失函数

本文在 MSE 损失的基础上,引入时空一致性损失(Spatio-Temporal Coherence loss),以个别变化作为预测降水量时空变化关系的软约束。时空一致性损失的目的是促使预测降水量之间的时空变化关系趋近于实际时空变化关系,其中的时空变化关系可以根据式(3)状态变化方程量化:

$$C_t = R_{t+1} - R_t + U_t \text{gd}_x(R_t) + V_t \text{gd}_y(R_t) \quad (16)$$

式中: U_t 和 V_t 描述了降雨随着时间从 R_t 移动至 R_{t+1} 时的移动向量,此处的 U_t 和 V_t 是通过光流法根据实际降水量计算得到的移动向量,式(3)中的 U_t 和 V_t 是根据历史状态所学的状态转移矩阵。由于光流法不适用于不满足强度守恒条件的暴雨,因此 C_t 实际上不仅包括降水量的时空变化关系,还可能

包含误差。对应的,预测结果 \hat{R}_{t+1} 、 \hat{R}_t 的时空变化关系为 \hat{C}_t 。

为了保持预测结果和实际降水量在时空变化关系上的一致性,本文定义时空一致性约束损失 L_{stc} ,计算预测降水量与实际降水量在连续时间步之间的时空变化率差异:

$$L_{stc} = MSE(C_{t+1:t+h-1}, \hat{C}_{t+1:t+h-1}) \quad (17)$$

式中: $C_{t+1:t+h-1}$ 是根据实际降水量 $R_{t+1:t+h}$ 计算的实际降水量的时空变化关系, $\hat{C}_{t+1:t+h-1}$ 是根据预测降水量

$\hat{R}_{t+1:t+h}$ 计算的预测降水量的时空变化关系。 $C_{t+1:t+h-1}$ 和 $\hat{C}_{t+1:t+h-1}$ 的下标取至 $t+h-1$ 是因为每2个相邻时间切片的降水可以计算一次变化率,因此对于 h 步预测来讲,只有 $h-1$ 步的时间变化率。

本文在估计单元和校正单元中均集成了MSE损失和STC损失,以确保估计和校正过程都能有效减少预测误差并维持时空一致性。训练总损失结合了估计和校正两部分的损失,可以表达为下列公式:

$$L = \underbrace{L_{mse}(R_{t-m+1:t+h}, \hat{R}_{t-m+1:t+h}) + \lambda L_{stc}(C_{t-m+1:t+h-1}, \hat{C}_{t-m+1:t+h-1})}_{L_{estimation}} + \underbrace{L_{mse}(R_{t-m+1:t+h}, \hat{R}_{t-m+1:t+h}) + \lambda L_{stc}(C_{t-m+1:t+h-1}, \hat{C}_{t-m+1:t+h-1})}_{L_{correction}} \quad (18)$$

式中: $L_{estimation}$ 针对估计结果; $L_{correction}$ 针对校正结果(最终预测结果); R_t 、 \hat{R}_t 和 \hat{R}_t 分别表示实际降水量、估计降水量和校正降水量(对应预测降水量); C_t 、 \hat{C}_t 和 C_t 分别表示实际降水量的时空变化量、估计降水量的时空变化量和校正降水量(对应预测降水量)的时空变化量。 λ 作为STC损失的权重,在实验中设置为1时达到了最佳的预测性能。

3 实验结果与分析

3.1 实验数据与设置

本文将所提出的所有方法在2个现实世界数据集上进行了测试:ERA5(the 5th generation ECMWF(European Centre for Medium-range Weather Forecasts Reanalysis)全球大气再分析数据^[23]和

NCEP(National Centers for Environmental Prediction)CFSv2(Climate Forecast System Version 2)精选小时序列产品^[24]。表1展示了本文所用的大气变量,表2说明了本文所用2个数据集的空间、时间和分辨率等信息。所选研究区域地处中国中部,覆盖长江中游/中下游,降水较为丰富,尤其在夏季,受东南季风和热带气旋的影响,降水更为充沛。为了避免未来数据泄露,本文按照所获取数据的年份顺序和7:2:1的数据集分配比例,简要划分了2个数据集的训练年份。

实验采用Pytorch深度学习框架,所有模型采用单个NVIDIA RTX 3090 GPU进行训练。本文数据时间步长为1 h。模型优化方法为Adam,初始学习率为 10^{-4} ,批大小取5。模型中的超参数 λ 为时空一致约束损失的加权参数,实验证明 $\lambda=1$ 时能够取得最高的预

表1 实验数据集大气变量

Tab. 1 Atmospheric variables of experimental datasets

ERA5数据集		NCEP数据集	
变量	单位	变量	单位
总降水量(Total precipitation)	m	总降水量(Total precipitation)	kg/m ²
2 m 温度(2m temperature)	K	温度(Temperature)	K
2 m 露点温度(2 m dewpoint temperature)	K	露点温度(Dewpoint temperature)	K
平均海平面气压(Mean sea level pressure)	Pa	平均海平面气压(Pressure reduced to mean sea level)	Pa
表面气压(Surface Pressure)	Pa	u 风(u-component of wind)	m/s
10 m u 风(10m u-component of wind)	m/s	v 风(v-component of wind)	m/s
10 m v 风(10m v-component of wind)	m/s	相对湿度(Relative humidity)	%
100 m u 风(100m u-component of wind)	m/s		
100 m v 风(100m v-component of wind)	m/s		

表2 实验数据集信息

Tab. 2 Information of experimental datasets

数据集信息	ERA5数据集	NCEP数据集
纬度范围/°N	28.125—33.125	25.25—35.2
经度范围/°E	113.125—118.125	107.75—117.75
空间分辨率/°	0.25	0.5
时间分辨率/h	1	1
训练数据/年	2000—2016	2011—2016
验证数据/年	2017—2019	2017—2018
测试数据/年	2020—2023	2019

测精度。所对比算法的学习率和批大小等参数以及训练器设置均参照原文设置。暴雨阈值取 16 mm。

3.2 评价指标

本文用平均绝对误差 (Mean Absolute Error, MAE) 来评估降水量预测结果。MAE 值越小,说明降水量预测的精确度越高。MAE 的计算公式如下:

$$MAE = \frac{1}{N} \sum_i \frac{1}{n_w \times n_h \times h} \sum_{x,y,t} |r_{x,y,t,i} - \hat{r}_{x,y,t,i}| \quad (19)$$

式中: $r_{x,y,t,i}$ 、 $\hat{r}_{x,y,t,i}$ 分别代表第 i 个样本 t 时格网 (x, y) 上的观测降水量和预测降水量; N 表示测试集的总样本数; n_w 、 n_h 分别表示格网在纵横 2 个方向的数量; h 表示预测时间步数。

本文用气象中常见的 2 个指标, CSI (Critical Success Index) 和 HSS (Heidke Skill Score) 来评估暴雨预测性能。因为暴雨很少发生,如果使用常规精度度量如 MAE 来衡量暴雨预测性能,可能会受到大量非暴雨格网的影响而不能直接反应暴雨预测性能。CSI 和 HSS 值越大,说明暴雨预测准确性越高,模型预测暴雨的能力越强。具体计算公式如下:

$$CSI = \frac{TP}{TP + FP + FN} \quad (20)$$

$$HSS = \frac{2 \times (TP \times TN - FN \times FP)}{(TP + FN)(FN + TN) + (TP + FP)(FP + TN)} \quad (21)$$

式中: TP 表示真阳性的个数,即正确预测的暴雨事件数; FP 表示假阳性的个数,即没有发生暴雨但是被预测为暴雨的事件数; FN 是假阴性的个数,即未预测到的暴雨事件数。

本文用度量集合预报可靠性的方式衡量模型

处理不确定性的能力。故此,本文用随机种子训练模型 5 次,获得 5 种模型权重参数,对应获得 5 种预测结果构成一个集合。集合离散度 (Spread) 体现的是集合成员的离散程度。离散度越小,预报不确定性越小;反之,离散度越大,预报不确定性越大。Spread 的计算公式如下:

$$SPREAD = \sqrt{\frac{1}{N} \sum_i \frac{1}{n_w \times n_h \times h} \sum_{x,y,t} \frac{1}{N_{ens}} \sum_k (\hat{r}_{x,y,t,i}^{(k)} - \bar{r}_{x,y,t,i})^2} \quad (22)$$

式中: $\hat{r}_{x,y,t,i}^{(k)}$ 表示第 k 个集合成员在样本 i 、时间 t 、格网 (x,y) 上的降水量预测值。 $\bar{r}_{x,y,t,i} = \frac{1}{N_{ens}} \sum_k \hat{r}_{x,y,t,i}^{(k)}$ 表示 N_{ens} 个集合成员的预测降水量的平均值。

3.3 对比分析

本文将所提出的暴雨预测方法 KalECNet 与 4 种先进的机器学习驱动的时空气象预测方法进行了预测性能比较: CNN^[25]、DGMR^[26]、FourcastNet^[19] 和 Rainformer^[10]。CNN 是基于数值预报结果的强对流天气 (包括暴雨、冰雹等) 预报模型,已被用于指导中国国家气象中心的业务预报; DGMR 为基于 ConvGRU 的生成模型,实现了准确的雷达降水概率临近预报; FourcastNet 结合了视觉转换器 (Vision Transformer) 和傅里叶神经算子,在小尺度变量预测 (如,降水量) 上优于最优数值模型; Rainformer 使用多头自注意力和门控融合单元,具有强大的高强度降水预测能力。

从 ERA5 和 NCEP 2 个现实世界数据集上的预测结果综合来看 (表 3), 所提 KalECNet 提供了最好的 CSI 和 HSS 值以及较低的 SPREAD 值,说明 KalECNet 能够实现准确且稳定暴雨预测。在 ERA5 数据集上, FourcastNet 虽然预测能力稳定,但其性能稳定在次优的 CSI 和 HSS 值上。FourcastNet 与 CNN 分别在 ERA5 和 NCEP 两个数据集上的 MAE 值相对较小,说明降水量预测误差整体较小,但是其暴雨预测指标低于 KalECNet,这说明 FourcastNet 与 CNN 可能更容易低估降水量。DGMR 在 4 种方法中相对表现不佳,这可能是由于作者将 DGMR 应用于 ERA5 和 NCEP 数据集时进行了简化,也可能是因为其过于复杂的网络无法在现有样本上充分发挥建模能力。

表3 KalECNet与对比方法在ERA5和NCEP数据集上的暴雨预测性能比较

Tab. 3 Comparison of rainstorm prediction performance between KalECNet and compared methods on ERA5 and NCEP datasets

方法	ERA5 数据集				NCEP 数据集			
	MAE ↓	CSI ↑	HSS ↑	SPREAD ↓	MAE ↓	CSI ↑	HSS ↑	SPREAD ↓
CNN	0.932	0.279	0.433	0.605	0.597	<u>0.166</u>	<u>0.279</u>	<u>0.482</u>
DGMR	1.642	0.155	0.262	18.126	1.121	0.078	0.140	1.574
FourcastNet	0.736	<u>0.281</u>	<u>0.436</u>	0.503	0.807	0.107	0.188	1.194
Rainformer	0.906	0.262	0.413	0.637	0.739	0.092	0.166	0.786
KalECNet	<u>0.857</u>	0.294	0.452	<u>0.546</u>	<u>0.644</u>	0.173	0.293	0.475

注:加粗数值为最优性能指标;加下划线数值为次优性能指标;↑表示该指标越大相对应的性能越好;↓表示该指标越小相对应的性能越好。

NCEP数据集相较于ERA5数据集而言,整体样本量和暴雨样本量较小。由于样本不足,各方法在NCEP数据集上的暴雨预测准确性均低于在ERA5数据集上的性能,但CNN和KalECNet的CSI值的下降程度较小。这说明CNN和KalECNet具备较强泛化能力,能够缓解样本量不足带来的负面影响,而FourcastNet和Rainformer的时空建模能力需要充足样本量支撑。其中,CNN的泛化能力可能得益于网络规模小,易于训练;所提KalECNet的泛化能力可以归功于模型中的个别变化约束和基于估计误差的气象状态校正机制。

3.4 消融分析

为了验证所提创新点的有效性,设置消融实验如下:①-EC:将估计误差指导的气象校正单元替换为传统ConvGRU;②-PP:去掉误差估计和指导环节,直接用观测状态校正估计状态;③-PHY:去掉个别变化的约束(包括模块和损失)。

从ERA5数据集上的预测结果来看(表4),在

模型中添加校正单元、根据误差校正气象状态和添加个别变化约束等策略均对提高暴雨预测准确性起到了重要作用。在模型中添加校正单元和根据误差进行气象状态校正对提高稳定性也起到了重要作用,而个别变化约束反而在缓解不确定性问题上起到了负面作用。这可能是因为物理约束所基于的假设不完全符合复杂多变的实际情况,其次单一物理理论难以准确约束由多个物理理论描述的非线性复杂动态变化,导致个别变化约束的引入增加了预测的不确定性。从NCEP数据集上的预测结果来看,在模型中添加校正单元反而阻碍了暴雨预测准确性的提升。这可能是因为样本量不充足的情况下,校正单元难以学习到正确的校正模式。在添加校正单元的情况下,基于误差的校正能够起到提升准确性的作用。

3.5 预测结果可视分析

图3可视化展示了所提KalECNet以及对比方法在3个不同模式的暴雨样本上的预测表现。图

表4 KalECNet消融方法在ERA5和NCEP数据集上的暴雨预测性能比较

Tab. 4 The comparison of rainstorm prediction performance between KalECNet and ablation methods on ERA5 and NCEP datasets

方法	ERA5 dataset				NCEP dataset			
	MAE ↓	CSI ↑	HSS ↑	SPREAD ↓	MAE ↓	CSI ↑	HSS ↑	SPREAD ↓
-EC	0.832	0.275	0.429	0.655	<u>0.586</u>	0.187	0.312	<u>0.458</u>
-PP	<u>0.820</u>	<u>0.292</u>	<u>0.450</u>	0.554	0.671	0.170	0.289	0.553
-PHY	0.806	0.285	0.441	0.517	0.545	0.123	0.218	0.338
KalECNet	0.857	0.294	0.452	<u>0.546</u>	0.644	<u>0.173</u>	<u>0.293</u>	0.475

注:加粗数值为最优性能指标;加下划线数值为次优性能指标;↑表示该指标越大相对应的性能越好;↓表示该指标越小相对应的性能越好。

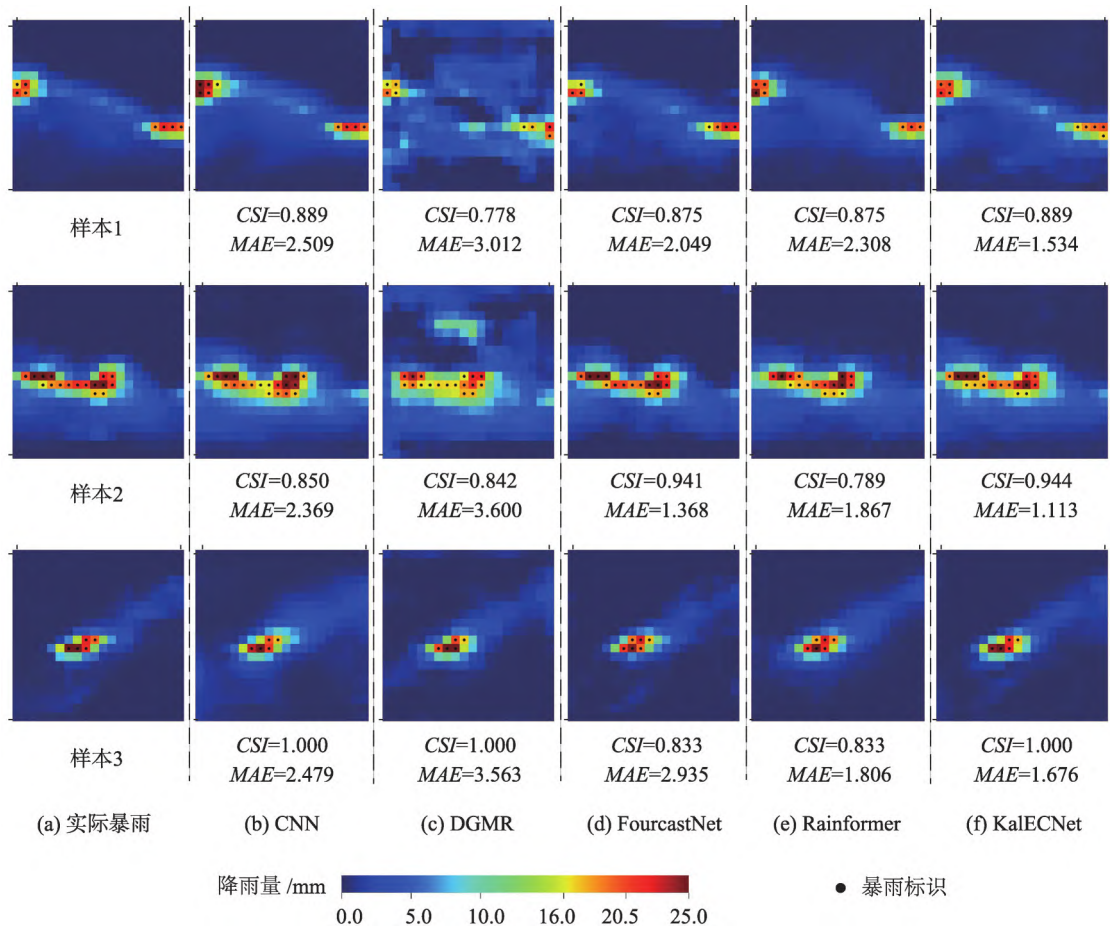


图3 KalECNet及对比方法的暴雨预测结果

Fig. 3 The prediction results of KalECNet and compared methods

中用色带展示了降水量预测结果,用黑点标识了暴雨格网(降水量 $\geq 16\text{ mm}$),并标注了该次预测的CSI和MAE值,其中MAE仅计算了实际暴雨网格的降水量误差值。如图3所示,所提KalECNet方法的预测降水量空间分布与实际相似,以格网为基础的暴雨位置预测正确,并实现了较为准确的暴雨降水量预测。CNN暴雨位置的预测基本正确,但高估暴雨降水量。FourcastNet和Rainformer暴雨位置的预测基本正确,但低估暴雨降水量。DGMR暴雨位置、降水量值和模式均存在偏差。总之,所提KalECNet方法成功预测到了暴雨发生及时空模式,验证了个别变化约束的气象状态估计和估计误差指导的气象状态校正具有提高暴雨预测水平的能力。

3.6 运行时间、参数量及内存分析

表5列出了KalECNet及对比模型的运行时间、训练参数量和所占用的GPU内存。CNN虽然在

表5 KalECNet及对比方法的模型运行时间、参数量和所占内存

Tab. 5 Model runtime, parameter size and GPU memory occupied by KalECNet and compared methods

方法	运行时间/s ↓	参数量/万 ↓	GPU内存/GB ↓
CNN	0.001	150	0.006
DGMR	0.048	13 654	0.516
FourcastNet	<u>0.025</u>	<u>5 888</u>	<u>0.220</u>
Rainformer	0.028	16 014	0.603
KalECNet	0.103	8 961	0.334

注:加粗数值为最优性能指标,加下划线数值为次优性能指标;
↑表示该指标越大相对应的性能越好;↓表示该指标越小相对应的性能越好。

ERA5数据集上的暴雨预测能力略低于FourcastNet和所提KalECNet,但运行速度快,参数量小,运行时所占GPU内存小,适用于计算资源不足或时效要求高或数据规模大的实际应用中。FourcastNet和所

提 KalECNet 的应用具有一定的计算资源要求,可以在计算资源充足的情况下满足较高精度的暴雨预测需求。KalECNet 的参数量和所占内存远小于 DGMR 和 Rainformer,但是运行时间却远大于 DGMR 和 Rainformer,这说明所提方法在计算效率上仍存在较大提升空间。

4 结论

针对暴雨过程、观测以及建模等环节可能存在的不确定性问题,本文提出基于“估计-校正”循环网络的暴雨临近预测方法 KalECNet,以个别变化理论为约束估计气象状态,并按照卡尔曼滤波器原理依据估计误差进行气象状态校正,实现准确和可靠的暴雨预测。实验证明:① 所提方法 KalECNet 在 ERA5 和 NCEP 2 个现实世界数据集上取得了最佳的暴雨预测准确性指标(CS 和 HSS)和良好的稳定性指标(SPREAD);② 根据误差校正气象状态和添加个别变化约束有利于提高暴雨预测准确性指标,而个别变化约束可能会引入新的不确定性不利于提高暴雨预测稳定性;③ KalECNet 预测的降水量空间分布与实际相似,以格网为基础的暴雨位置预测正确,并实现了较为准确的暴雨降水量预测。此外,所提方法在计算效率上仍存在较大提升空间。在未来的研究中,可以继续提高所提方法的计算效率,并尝试将所提方法应用于暴雨的集合预报中。

致谢:本论文的数值计算得到了武汉大学超级计算中心的计算支持和帮助。

利益冲突: Conflicts of Interest

所有作者声明不存在利益冲突。

All authors disclose no relevant conflicts of interest.

作者贡献: Author Contributions

刘杰和张彤参与实验设计并完成实验;刘杰、张彤、王培晓、韩士元、冷亮和肖艳姣参与论文的写作与修改。所有作者均阅读并同意最终稿件的提交。

This study was designed by LIU Jie and ZHANG Tong. The experiments was completed by LIU Jie and ZHANG Tong. The manuscript was drafted and revised by LIU Jie, ZHANG Tong, WAWNG Peixiao, HAN Shiyuan, LENG Liang and XIAO Yanjiao. All authors have read the last version of paper and consented for submission.

参考文献(References):

- [1] 赵晓凤,刘维. 2021 年秋收作物生长季农业气象条件评价[J]. 中国农业气象,2022,43(1):72-76. [Zhao X F, Liu W. Analysis report of agrometeorological conditions during growing season of autumn-harvest crops in 2021[J]. Chinese Journal of Agrometeorology, 2022, 43(1):72-76.] DOI:10.3969/j.issn.1000-6362.2022.01.007
- [2] 苏爱芳,吕晓娜,崔丽曼,等. 郑州"7.20"极端暴雨天气的基本观测分析[J]. 暴雨灾害,2021,40(5):445-454. [Su A F, Lv X N, Cui L M, et al. The basic observational analysis of "7.20" extreme rainstorm in Zhengzhou. Torrential Rain and Disasters, 2021,40(5):445-454.] DOI: 10.3969/j.issn.1004-9045.2021.05.001
- [3] Sun J, Niu Z, Innanen K A, et al. A theory-guided deep-learning formulation and optimization of seismic waveform inversion Theory-guided DL and seismic inversion[J]. Geophysics, 2020,85(2):R87-R99. DOI:10.1190/GEO2019-0138.1
- [4] Bech J, Chau J L. Doppler radar observations: Weather radar, wind profiler, ionospheric radar, and other advanced applications[M]. BoD-Books on Demand, 2012. DOI:10.5772/2036
- [5] Buehner M, Jacques D. Non-Gaussian deterministic assimilation of radar-derived precipitation accumulations [J]. Monthly Weather Review, 2020,148(2):783-808. DOI: 10.1175/MWR-D-19-0199.1
- [6] Kashinath K, Mustafa M, Albert A, et al. Physics-informed machine learning: case studies for weather and climate modelling[J]. Philosophical Transactions of the Royal Society A, 2021,379(2194):20200093. DOI:10.1098/rsta.2020.0093
- [7] 薛丰昌,章超钦,王文硕,等. 基于自注意力和门控循环神经网络的雷达回波外推算法研究[J]. 气象学报,2024,82(1):127-135. [Xue F C, Zhang C Q, Wang W S, et al. Improving radar echo extrapolation algorithms based on self-attention and gated recurrent neural networks[J]. Acta Meteorologica Sinica, 2024,82(1):127-135.] DOI:10.11676/qxxb2024.20230053
- [8] 王善昊,胡志群,王福增,等. 基于 ConvLSTM 融合 RMAPS-NOW 数据的雷达回波外推研究[J]. 气象学报,2024,82(4):1-14. [Wang S H, Hu Z Q, Wang F Z, et al. A study on radar echo extrapolation based on ConvLSTM fusion of RMAPS-NOW data[J]. Acta Meteorologica Sinica, 2024, 82(4):1-14.] DOI:10.11676/qxxb2024.20230135
- [9] 李泽椿,张玲,钱奇峰,等. 中央气象台台风预报业务的发展及思考[J]. 大气科学学报,2020,43(1):10-19. [Li Z C, Zhang L, Qian Q F, et al. The development and consider-

- ation of typhoon forecast operation of national meteorological center[J]. Transactions of Atmospheric Sciences, 2020,43(1):10-19.] DOI:10.13878/j.cnki.dqkxxb.20200110015
- [10] Bai C, Sun F, Zhang J, et al. Rainformer: Features extraction balanced network for radar-based precipitation nowcasting[J]. IEEE Geoscience and Remote Sensing Letters, 2022,19:1-5. DOI:10.1109/LGRS.2022.3162882
- [11] Zhang T, Liu J, Wang J. Rainstorm prediction via a deep spatio-temporal-attributed affinity network[J]. Geocarto International, 2022,37(26):13079-13097. DOI:10.1080/10106049.2022.2076914
- [12] Huang X, Luo C, Ye Y, et al. Location-refining neural network: A new deep learning-based framework for Heavy Rainfall Forecast[J]. Computers & Geosciences, 2022, 166:105152. DOI:10.1016/j.cageo.2022.105152
- [13] Hess P, Boers N. Deep learning for improving numerical weather prediction of heavy rainfall[J]. Journal of Advances in Modeling Earth Systems, 2022,14(3):e2021MS002765. DOI:10.1029/2021MS002765
- [14] Hess P, Drüke M, Petri S, et al. Physically constrained generative adversarial networks for improving precipitation fields from Earth system models[J]. Nature Machine Intelligence, 2022,4: 828-839. DOI: 10.1038/s42256-022-00540-1
- [15] Gao Z, Shi X, Han B, et al. PreDiff: Precipitation nowcasting with latent diffusion models[J]. Advances in Neural Information Processing Systems, 2023, 36:78621-78656.
- [16] Ritvanen J, Harnist B, Aldana M, et al. Advection-free convolutional neural network for convective rainfall nowcasting[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2023,16:1654-1667. DOI:10.1109/JSTARS.2023.3238016
- [17] Zhang Y, Long M, Chen K, et al. Skilful nowcasting of extreme precipitation with NowcastNet[J]. Nature, 2023,619(7970):526-532. DOI:10.1038/s41586-023-06184-4
- [18] Li L, Carver R, Lopez-Gomez I, et al. Generative emulation of weather forecast ensembles with diffusion models[J]. Science Advances, 2024, 10(13): eadk4489. DOI:10.1126/sciadv.adk4489
- [19] Pathak J, Subramanian S, Harrington P, et al. FourCastNet: A global data-driven high-resolution weather model using adaptive fourier neural operators[C]. International Conference on Learning Representations, 2022. DOI:10.48550/arXiv.2202.11214
- [20] Hu Y, Chen L, Wang Z, et al. SwinVRNN: A data-driven ensemble forecasting model via learned distribution perturbation[J]. Journal of Advances in Modeling Earth Systems, 2023,15(2):e2022MS003211. DOI:10.1029/2022 MS003211
- [21] Price I, Sanchez-Gonzalez A, Alet F, et al. Gencast: Diffusion-based ensemble forecasting for medium-range weather[J]. arXiv preprint arXiv:2312.15796, 2023.
- [22] Anderson J D, Wendt J. Computational fluid dynamics: 206[M]. Springer, 1995.
- [23] Hersbach H, Bell B, Berrisford P, et al. ERA5 hourly data on single levels from 1979 to present. Copernicus Climate Change Service (C3S) Climate Data Store (CDS). 2018. DOI:10.24381/cds.adbb2d47
- [24] Saha S, et al. 2011. NCEP climate forecast system version 2 (CFSv2) selected hourly time-series products. Research Data Archive at the National Center for Atmospheric Research, Computational and Information Systems Laboratory. <https://doi.org/10.5065/D6N877VB>
- [25] Zhou K, Zheng Y, Li B, et al. Forecasting different types of convective weather: A deep learning approach[J]. Journal of Meteorological Research, 2019,33(5): 797-809. DOI: 10.1007/s13351-019-8162-6
- [26] Ravuri S, Lenc K, Willson M, et al. Skilful precipitation nowcasting using deep generative models of radar[J]. Nature, 2021,597(7878):672-677. DOI: 10.1038/s41586-02103854-z

■ 本文图文责任编辑: 黄光玉 蒋树芳