

引用格式:钟诚,吴升,王培晓,等.先验与数据双引导的城市居民活动强度预测模型[J].地球信息科学学报,2025,27(10):2453-2465. [Zhong C, Wu S, Wang P X, et al. Prior- and data-guided model for predicting urban human activity intensity[J]. Journal of Geo-information Science, 2025,27(10):2453-2465.] DOI:10.12082/dqxxkx.2025.250198; CSTR:32074.14.dqxxkx.2025.250198

先验与数据双引导的城市居民活动强度预测模型

钟 诚¹,吴 升¹,王培晓^{2,3*},张恒才^{2,3},程诗奋^{2,3},陆 锋^{2,3}

1. 福州大学数字中国研究院(福建),福州 350108; 2. 中国科学院地理科学与资源研究所 地理信息科学与技术全国重点实验室,北京 100101; 3. 中国科学院大学资源与环境学院,北京 100049

Prior- and Data-Guided Model for Predicting Urban Human Activity Intensity

ZHONG Cheng¹, WU Sheng¹, WANG Peixiao^{2,3*}, ZHANG Hengcai^{2,3}, CHENG Shifen^{2,3}, LU Feng^{2,3}

1. The Academy of Digital China (Fujian), Fuzhou University, Fuzhou 350108, China; 2. State Key Laboratory of Geographic Information Science and Technology, Institute of Geographic Sciences and Natural Resources Research, Chinese Academy of Sciences, Beijing 100101, China; 3. College of Resources and Environment, University of Chinese Academy of Sciences, Beijing 100049, China

Abstract: [Significance] Accurate prediction of urban residents activity intensity is a fundamental research topic in Geospatial Artificial Intelligence (GeoAI), with important applications in urban planning, traffic management, and public safety. Although numerous predictive models have been proposed, effectively mining functional similarity among urban mixed-use areas as a prior to guide prediction remains a major challenge. Due to their composite nature, mixed-use areas exert differentiated impacts on resident activities across different time periods. Measuring multi-functional similarity based on diverse functional features and incorporating it as a prior into spatial dependency modeling holds promise for improving prediction accuracy. [Methods] To address this, the study proposes a novel Prior- and Data-Guided Spatio-Temporal Prediction Model (PDGSTPM). First, a hyperedge construction mechanism is designed within a hypergraph theoretical framework to represent urban functional semantics. Through self-supervised learning, the mixed functional characteristics encoded by POIs are explicitly transformed into a quantifiable, high-order multi-relational network. This enables the construction of functional similarity priors and facilitates a shift in spatial dependency modeling from first-order pairwise relationships to high-order structures. Second, a multi-granular similarity measurement method based on 1-Wasserstein Distance is introduced to capture morphological consistency in historical observation sequences, enabling data-level similarity representation that complements the functional similarity prior. Finally, by integrating both prior-guided and data-driven modeling approaches, a dual-guided graph neural network architecture is developed to accurately model complex spatio-temporal dependencies. [Results] Experiments were conducted to predict urban human activity intensity using mobile phone data from Xiamen City in March 2023. Compared with the best-performing baseline method, the proposed model reduced *RMSE* and *MAE* by 3.2% and 9.1%, respectively, for one-step prediction, and by 5.6% and 9.8%, respectively, for two-step prediction. [Conclusions] The experimental results validate the

收稿日期:2025-04-27;修回日期:2025-06-07.

基金项目:国家重点研发计划项目(2023YFB3906804)。[Foundation item: National Key Research and Development Program of China, No.2023YFB3906804.]

作者简介:钟 诚(1991—),男,安徽铜陵人,硕士生,主要从事地理大数据分析研究。E-mail: 235520031@fzu.edu.cn

*通讯作者:王培晓(1994—),男,山东济南人,博士,助理研究员,主要从事时空数据分析、时空预测、轨迹分析等研究。

E-mail: wpw@lreis.ac.cn

effectiveness of the proposed dual-guidance architecture in accurately modeling spatio-temporal dependencies.

Key words: GeoAI; prior guidance; data-driven; spatio-temporal prediction; urban human activity intensity

***Corresponding author:** WANG Peixiao, E-mail: wpx@lreis.ac.cn

摘要:【意义】城市居民活动强度的精准预测是地理空间人工智能的基础研究命题,在城市规划、交通管理及公共安全等领域具有重要应用价值。尽管已有多种城市居民活动强度预测模型被提出,但如何挖掘城市混合功能区之间的功能相似性作为先验引导预测仍是一大挑战。由于其复合功能特性,混合功能区在不同时段对居民活动呈现出差异化影响,通过多种功能特征度量多元功能相似性,并将其作为先验引导空间依赖建模,有望提升预测精度。【方法】本研究提出一种新颖的先验与数据双引导的时空预测模型(Prior- and Data-Guided Spatio-Temporal Prediction Model, PDGSTPM)。首先,本研究基于超图理论框架设计了面向城市功能语义的超边构建机制,利用自监督学习将POI表征的混合城市功能特性显式编码为可量化分析的高阶多元关联网络进而表征多元功能相似性先验,实现了城市区域间空间依赖建模由一阶对偶关系向高阶多元结构的突破;然后,本研究利用一阶瓦瑟斯坦距离建立了历史观测数据的多粒度相似性度量方法,通过捕捉居民活动强度序列中的形态一致性挖掘观测数据中隐含的变化特性来进行数据层面的相似性表征,以实现数据层面相似性与功能相似性先验的互补;最后,本研究融合先验引导与数据驱动的双重建模机制,通过先验-数据双引导的图神经网络架构,实现复杂时空依赖关系的精准建模。【结果】本研究采用2023年3月的厦门市手机定位数据进行了城市居民活动强度预测实验,相比于基线方法,PDGSTPM模型在RMSE和MAE两项指标上,单步预测精度分别提升了3.2%和9.1%,双步预测精度分别提升了5.6%和9.8%。【结论】实验结果验证了PDGSTPM模型在精准建模时空依赖关系方面的优势。

关键词:地理空间人工智能;先验引导;数据引导;时空预测;城市居民活动强度

1 引言

城市居民活动强度指的是一段时间内城市各研究单元中分布的居民数量,能够实时、动态地反映出人口数量的差异及其随时间变化的模式^[1]。对城市居民活动强度开展前瞻性预测,能够帮助城市管理者精准锚定潜在的高强度与低强度区域,对防范交通拥堵、保障公共安全,建设智慧城市具有重要意义^[2-3]。

城市居民活动强度预测本质上是时空预测任务,一直以来备受国内外众多学者关注。由于设备算力和数据来源限制等原因,早期的居民活动强度预测主要采用先验引导的预测模型。此类方法假定时空现象在空间或时间维度上遵循明确的数学规律,从而构建特定的参数表达式来预测未来的时空状态。然而,先验引导的预测模型无法捕捉复杂的、非线性的时空依赖关系,造成精度损失的问题^[4-5]。随着大数据技术的快速发展与设备计算能力的显著提升,数据引导的预测模型成为当下主流的城市居民活动强度预测模型^[6-7]。相较于先验引导的预测模型,数据引导的预测模型具有天然的优势,不需要建立显式数学表达式,仅通过历史数据建立输入与输出之间的非线性时空依赖关系。目前,面向图结构的深度神经网络模型是最常见的时空预测建模手段^[8-11]。例如, Li等^[12]将研究区域抽象为图结构,基于物理空间和社交空间的交互强度分别构建边的权重,使用图卷积神经网络来学习空间依赖关系。Liu等^[13]则将注意力机制、门控循环单元和图卷积神经网络相结合,使用图卷积神经网络学习空间依赖关系之后再使用注意力机制增强对其特征的学习。Li等^[14]基于人流量来构建图模型边的权重,使用word2vec算法来学习图节点的高阶交互关系,并结合时序特征对人群的分布进行预测。Wang等^[15]将研究区域分别抽象为图和超图结构,使用图卷积神经网络和超图卷积神经网络来学习空间依赖关系。

深度图神经网络被广泛应用的根本原因在于,图结构既能够灵活建模空间依赖关系,又可作为一种先验知识,显式表征研究单元之间的拓扑关系。先验知识能够帮助模型捕捉数据层面难以识别的特征,从而提升模型的预测表现^[15]。除了图结构提供的空间拓扑信息外,POI数据提供的城市功能等信息也是城市问题研究中重要的先验来源。近年来,基于POI的先验知识与观测数据双引导的预测模型在预测精度与泛化能力方面展现出显著优势,并成为当下的研究热点。然而,当下双引导预测模型在深入挖掘先验知识并使用其引导空间依赖关系学习的方面仍不充分。例如,现有研究常以研究单元间的“POI序列距离”作为衡量区域功能相似性的指标^[16-17]。然而,城市功能类型高度异质,研究单元往往同时具备多种功能属性,如兼具住宅功能和商业功能,单一“序列距离”维度难以全面表征其功能相似性,亟需构建多元的综合相似性度量体系,

基于高阶多元关系而非一阶对偶关系来深入表征多元功能相似性。然而,如何有效建模并实现这种复杂结构性表达进而将其应用于深度图神经网络空间依赖建模的引导,仍是当前面临的关键挑战。

鉴于此,本研究提出一种新颖的先验与数据双引导时空预测模型(Prior- and Data-Guided Spatio-Temporal Prediction Model, PDGSTPM)用于城市居民活动强度预测。具体而言,首先,本研究基于超图理论和POI数据设计了面向城市功能语义的超边构建机制,通过自监督学习捕捉格网和城市功能之间的多对多关系中隐式表征的多元功能相似性这一先验,实现一阶对偶关系向高阶多元关系的突破;其次,本研究从纯数据层面捕捉研究单元之间居民活动强度变化趋势的相似性,以便和先验知识互相补充;最后,本研究融合先验引导与数据驱动的双重建模机制,通过先验-数据双引导的图神经网络架构,实现复杂时空依赖关系的精准建模。

2 研究方法

城市居民活动强度预测本质上是一种时间序列映射任务,即通过构建适当的预测模型,将历史的城市居民活动强度序列映射至未来的活动强度序列^[1,12]。其数学表达形式如下:

$$\{\hat{x}^{t+1}; \hat{x}^{t+2}; \dots; \hat{x}^{t+Q}\} = f(x^{t-L+1}; x^{t-L+2}; \dots; x^t) \quad (1)$$

式中: f 表示本研究提出的PDGSTPM; $x^t \in R^{N \times 1}$ 表示第 t 个时间步的真实城市居民活动强度; \hat{x}^{t+Q} 表示预测的第 $t+Q$ 个时间步的城市居民活动强度; N 表示研究单元个数; L 表示输入的历史依赖步数; Q 表示预测步数。

如图1所示,本研究提出的PDGSTPM主要由3个核心模块组成:面向多元功能相似先验的约束矩阵构建、面向观测数据相似的邻接约束矩阵构建和




图1 PDGSTPM的整体架构

Fig. 1 Framework of PDGSTPM

双引导的时空依赖关系学习。其中,面向多元功能相似先验的约束矩阵构建挖掘格网和城市功能之间的多对多关系中隐式表征的多元功能相似性这一先验,实现一阶对偶关系向高阶多元关系的突破;面向观测数据相似的邻接约束矩阵构建则从纯数据层面捕捉研究单元间居民活动强度变化趋势的相似性,以便和先验知识互相补充;双引导的时空依赖关系学习框架通过先验引导的超图卷积与数据引导的图注意力机制协同建模空间依赖关系,并结合双引导融合模块、时间卷积网络以及输出层,实现对时空动态的高精度预测。3个模块独立运行,前2个模块基于POI和活动强度数据进行先验与数据相似性的离线学习,其结果用于第三模块中的在线预测,从而在对建模过程进行精确引导的同时避免多模块协同训练、预测带来的效率损耗。

2.1 面向多元功能相似先验的约束矩阵构建

城市居民活动强度的时间变化模式同研究单元的功能特性息息相关,办公功能区和住宅功能区表现出相反的时间变化模式^[18]。基于城市功能特性深入挖掘研究单元间的功能相似性,并将其用于对深度学习模型参数施加稀疏化约束,有助于显著提升模型精度。POI作为一种较易获取的数据源,被广泛应用于城市功能特性的显式表征当中^[19-20]。然而,本研究认为基于POI序列计算的距离难以全面刻画具备混合功能格网间的相似性。混合功能格网内城市居民活动常受特定时间

段内主导功能的引导,如白天以办公功能为主,夜间则以住宅功能为主。单一的POI序列距离容易掩盖该种时间敏感的功能差异,导致不同城市功能在影响力上的简单平均而忽略特定功能在特定时间下的重要性。因此,若要建模混合功能格网之间的相似性,需要构建多元评价体系。

如图2所示,格网与城市功能之间的多元关系与超图理论中的“超图节点-超边”结构高度契合。一个格网具备多种城市功能对应一个超图节点被多条超边连接,一种城市功能覆盖多个格网对应一条超边连接多个超图节点。因此,本研究构建超图 $G = \langle V, E, A_{\text{Prior}} \rangle$ 来建模格网与城市功能间的多对多关系,其中超图节点 $V = \{v_i\}_{i=1}^N$ 表示研究区域内的 N 个格网,超边 E 表示城市功能, $A_{\text{Prior}} \in R^{N \times M}$ 表示了格网与城市功能之间的高阶多元关系(蕴含多元功能相似性先验知识), M 表示城市功能数, $A_{\text{prior}}[i, j] = 1$ 表示格网 i 拥有城市功能 j)。由于城市功能高度异质,直接使用POI的类别无法准确且全面地表征,故而本研究参考Wang等^[1]的研究,将 M 设定为 N 的 0.4 倍,通过自监督的方式学习 A_{Prior} 并将其作为“多元功能相似性先验约束矩阵”引导后续自适应超图卷积的建模。

自监督学习是通过输入特征本身构造标签来进行监督训练的机器学习方法。鉴于城市混合功能难以清晰明确地量化表征,本研究通过将重分类后的POI与格网进行空间叠置构造表征格网内POI序列的“格网-POI矩阵”(重分类标准见表1),并通过自监督学习求得“多元功能相似性先验约束




图2 格网-城市功能多元关系表征

Fig. 2 Multi-relational representation between grids and urban functions

表1 POI重分类

Tab. 1 POI Reclassification

序号	原始类别	重分类
1	旅游景点	旅游景点类
2	科教文化	科教文化类
3	公司企业	公司企业类
4	商务住宅	商务住宅类
5	交通设施	交通设施类
6	汽车相关	基础生活配套设施类
7	生活服务	基础生活配套设施类
8	金融机构	基础生活配套设施类
9	酒店住宿	娱乐消费类
10	休闲娱乐	娱乐消费类
11	运动健身	娱乐消费类
12	购物消费	娱乐消费类
13	餐饮美食	娱乐消费类
14	医疗保健	医疗保健类

矩阵” A_{prior} 。如图3所示,具体而言,本研究首先随机初始化形状为 $N \times M$ 的矩阵,接着通过多元关系学习模块求得“格网-城市功能超图权重矩阵” $W_{\text{Grid-func}} \in R^{N \times M}$ 去表征各格网同不同城市功能的联系(值越大联系越紧密);其次,本研究通过随机行掩膜、行替换和行保留扰动“格网-POI矩阵”,实现自监督学习中的训练样本构建。最后,本研究通过优化预测“格网-POI矩阵”中的预测行与原始行的差异进行 A_{prior} 的学习。

$$\begin{cases} W_{\text{Grid-func}} = \text{softmax}(\text{topk}(\text{Conv1D}(W_{\text{Random}}))) \\ \hat{M}_{\text{Grid-poi}} = FNN_{\text{Reduce}}((W_{\text{Grid-func}} \cdot W_{\text{Grid-func}}^T) \cdot \\ FNN_{\text{Expand}}(\tilde{M}_{\text{Grid-poi}})) \end{cases} \quad (2)$$

式中: $W_{\text{Random}} \in R^{N \times M}$ 表示随机初始化的矩阵; Conv1D 表示卷积核大小为3的一维卷积; softmax 将每行最大的若干个值归一化(归一化的数值占 M 的比例为

λ_i); $\hat{M}_{\text{Grid-poi}} \in R^{N \times F}$ 表示预测的“格网-POI矩阵”; F 为表1中重分类后的POI类别数; FNN_{Expand} 和 FNN_{Reduce} 分别表示升维前馈神经网络和降维前馈神经网络; $\tilde{M}_{\text{Grid-poi}} \in R^{N \times F}$ 表示受扰动的“格网-POI矩阵”。当自监督模型收敛时,对 $W_{\text{Grid-func}}$ 进行二值化处理求得“多元功能相似性先验约束矩阵” A_{Prior} 。

2.2 面向观测数据相似的邻接约束矩阵构建

数据引导可以从样本中挖掘新的联系,与先验信息互补,从而提升空间依赖建模的完整性和准确性。一阶瓦瑟斯坦距离作为衡量2个分布差异的有效工具,基于概率分布与成本矩阵进行综合考量,为从数据层面刻画格网间活动强度序列变化的形态相似性提供了新的思路^[21]。本研究以居民活动强度序列为基础,显式建模其日与时间步不同尺度的特征,分别构建日尺度的概率分布以及基于时间步的日内活动差异矩阵,作为一阶瓦瑟斯坦距离计算中所需的概率分布与成本矩阵,以实现融合不同时间尺度的序列相似性度量,具体流程如图4所示。

一般而言,城市居民活动模式在工作日和周末之间呈现出显著差异,为了表征该种差异,本研究构建研究对象的日尺度概率分布。首先,基于训练集中居民活动强度序列构造居民活动强度三维张量 $x \in R^{N \times D \times T}$,其中 N 表示格网数, D 表示训练集中的天数, T 表示每天的时间步数。然后,本研究基于该张量构建日尺度概率分布。

$$\begin{cases} s_i^d = \|x[i, d]\|_2 \in \{s_i^d\}_{d=1}^D \\ p_i = \{p_i^d\}_{d=1}^D = \left\{ \frac{s_i^d}{\sum_{k=1}^D s_i^k} \right\}_{d=1}^D \end{cases} \quad (3)$$

式中: $p_i \in R^D$ 表示格网*i*对应的概率分布; $x[i, d] \in R^T$ 为*x*中切片选择的格网*i*第*d*目的活动强度向量;




图3 面向多元功能相似的约束矩阵构建

Fig. 3 Construction of constraint matrix based on multi-functional similarity prior




图4 面向观测数据相似的邻接约束矩阵构建

Fig. 4 Construction of adjacency constraint matrix based on observed data similarity

$\{s_i^d\}_{d=1}^D \in R^D$ 为格网 i 的一个中间向量; $\|\cdot\|_2$ 表示 L2 范数计算。

居民活动强度除了呈现工作日和周末等日尺度差异以外,在每日早晚高峰、昼夜等时间步尺度也呈现出显著差异,为了度量该种差异,本研究构建基于时间步的日内活动差异矩阵:

$$\mathbf{B}_{i \leftrightarrow j}[k, l] = \text{cosdis}(\mathbf{x}[i, k], \mathbf{x}[j, l]) \in \mathbf{B}_{i \leftrightarrow j} \quad (4)$$

式中: $\mathbf{B}_{i \leftrightarrow j} \in R^{D \times D}$ 表示格网 i 和格网 j 的日内活动差异矩阵; cosdis 表示余弦距离计算; $\mathbf{B}_{i \leftrightarrow j}[k, l]$ 为 $\mathbf{B}_{i \leftrightarrow j}$ 中第 k 行第 l 列的值。

在计算格网 i 和格网 j 的日内活动差异矩阵和日尺度概率分布的基础上,本研究进一步求解格网 i 和格网 j 的一阶瓦瑟斯坦距离。

$$\left\{ \begin{array}{l} \text{Was}(\mathbf{p}_i, \mathbf{p}_j) = \min_{P_{i \leftrightarrow j} \in \prod(p_i, p_j)} \sum_{k=1}^D \sum_{l=1}^D \mathbf{P}_{i \leftrightarrow j}[k, l] \mathbf{B}_{i \leftrightarrow j}[k, l] \\ \text{s.t.} \begin{cases} \sum_{l=1}^D \mathbf{P}_{i \leftrightarrow j}[k, l] = \mathbf{p}_i[k], \forall k \\ \sum_{k=1}^D \mathbf{P}_{i \leftrightarrow j}[k, l] = \mathbf{p}_j[l], \forall l \\ \mathbf{P}_{i \leftrightarrow j}[k, l] \geq 0, \forall k, l \end{cases} \end{array} \right. \quad (5)$$

式中: $\text{Was}(\mathbf{p}_i, \mathbf{p}_j)$ 为格网 i 和格网 j 的一阶瓦瑟斯坦距离; $\mathbf{P}_{i \leftrightarrow j}$ 为 2 个分布 \mathbf{p}_i 和 \mathbf{p}_j 的联合分布。本研究基于所有格网对间的一阶瓦瑟斯坦距离构建“数据相似性邻接约束矩阵” $A_{\text{Data}} \in R^{N \times N}$ 。具体而言,本研究将目标格网 i 的最近若干个格网设为邻居(每个目标格网的邻居个数占格网总数 N 的比例为 λ_2),若格网 j 在格网 i 的邻居中,则 $A_{\text{Data}}[i, j]$ 为 1,否则为 0。

2.3 双引导的时空依赖关系学习

城市格网的依赖关系呈现出显著的动态时变性,要对居民活动强度做出精准预测,需在自适应地

捕捉格网间时空依赖的基础上充分利用前述构建的先验和数据约束矩阵引导模型聚焦于真正存在依赖关系的格网。如图 5 所示,在先验引导方面,本文利用 2.1 节中学习到的“多元功能相似性先验约束矩阵”引导超图卷积神经网络的前向传播过程;在数据引导方面,本文采用 2.2 节中学习到的“数据相似性邻接约束矩阵”约束图注意力网络的前向传播过程。

先验引导的超图卷积部分,“多元功能相似性先验约束矩阵” A_{Prior} 主要用于约束超图卷积运算中的自适应权重 $\mathbf{W}_{\text{Adaptive}} \in R^{N \times M}$, 实现自适应的超图关系矩阵的稀疏化。

$$\left\{ \begin{array}{l} \bar{\mathbf{A}}_{\text{Prior}} = \mathbf{W}_{\text{Adaptive}} \odot \mathbf{A}_{\text{Prior}} \\ \hat{\mathbf{X}}_{\text{Prior}} = \sigma(\mathbf{D}_{\text{Node}}^{-1} \cdot \bar{\mathbf{A}}_{\text{Prior}} \cdot \mathbf{W} \cdot \mathbf{D}_{\text{Edge}}^{-1} \cdot \bar{\mathbf{A}}_{\text{Prior}}^T \cdot \text{TempConv}(\mathbf{X}) \cdot \mathbf{W}_{\text{HGCN}}) \end{array} \right. \quad (6)$$

式中: $\hat{\mathbf{X}}_{\text{Prior}}$ 为先验引导的超图卷积输出; \odot 表示哈德玛积; $\bar{\mathbf{A}}_{\text{Prior}} \in R^{N \times M}$ 为中间矩阵; \mathbf{D}_{Node} 和 \mathbf{D}_{Edge} 分别表示超图节点和超边的度矩阵; $\mathbf{W}_{\text{HGCN}} \in R^{h \times h}$ 为可学习的权重矩阵; h 为隐藏维度; σ 表示非线性激活函数; TempConv 表示时间卷积神经网络; $\mathbf{W} \in R^{M \times M}$ 为单位矩阵; $\mathbf{X} \in R^{N \times L}$ 为所有格网的居民活动强度序列。本研究对时间卷积网络的输出进行超图卷积。为了避免梯度爆炸或者消失等问题,本研究对超图卷积添加残差连接。

数据引导的图注意力部分,“数据相似性邻接约束矩阵” A_{Data} 主要用于约束图注意力运算中的图邻域,实现自适应的图权重的稀疏化。

$$\left\{ \begin{array}{l} \mathbf{h}_i = \sigma(\sum_{j \in \{j | A_{\text{Data}}[i, j] = 1\}} \alpha_{ij} \cdot \mathbf{h}_j \cdot \mathbf{W}_{\text{GAT}}) \\ \hat{\mathbf{X}}_{\text{Data}} = \text{TransConv}(\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_N) \end{array} \right. \quad (7)$$

式中: $\hat{\mathbf{X}}_{\text{Data}}$ 为数据引导图注意力神经网络的输出; α_{ij} 为注意力得分; $\mathbf{W}_{\text{GAT}} \in R^{h \times h}$ 为可学习的权重矩阵;




图5 双引导的时空依赖关系学习

Fig. 5 Dual-guided spatio-temporal dependency learning

$\{\mathbf{h}_i\}_{i=1}^N$ 表示各格网对应活动强度序列的嵌入向量; $TransConv$ 表示从各嵌入向量到输出的映射。本研究对图注意力添加残差连接。

最后,本研究使用双引导融合模块对先验和数据引导的结果进行融合,实现二者的优势互补:

$$\hat{\mathbf{X}}_{\text{Out}} = \text{ReLU}(\text{concat}(\hat{\mathbf{X}}_{\text{Prior}}, \hat{\mathbf{X}}_{\text{Data}}) \cdot \mathbf{W}_F) \quad (8)$$

式中: $\mathbf{W}_F \in R^{2h \times h}$ 为可学习的权重矩阵; concat 表示拼接操作。在双引导的时空依赖关系学习中,本研究采用“时-空-时”架构,依次学习时间依赖、空间依赖和时间依赖,并将该架构堆叠两层。对于单步预测任务,对时空依赖关系学习的输出进行时间步维度的切片,取出最后一个时间步并使用一次线性变换和 $ReLU$ 激活函数将隐藏维度 h 降至输出维度 1;对于多步预测任务,则保留完整的时间步维度,通过 2 次线性变换对齐输出维度和预测的时间步数。本研究计算预测值和真实值之间的均方根误差(Root Mean Square Error, RMSE)进行反向传播。

2.4 基线方法与定量评价指标

为了验证提出的模型之有效性,本研究选取了若干经典和前沿的深度学习方法以及基于 POI 序列距离来挖掘先验的 PDGTPM 进行比较。

(1) LSTM:LSTM 的全称为长短期记忆网络,是一种经典的时序预测模型,常常用于交通流等预测任务中。

(2) STGCN:STGCN 分别采用图卷积神经网络和门控卷积神经网络分别学习空间和时间依赖,是经典的深度学习时空预测模型。

(3) ASTGCN: ASTGCN 除了使用图卷积神经网络和卷积神经网络学习空间、时间依赖关系以外,还使用注意力机制对输入数据进行处理以捕捉重点的时空特征。

(4) T-GCN: T-GCN 将图卷积神经网络和门控循环单元相结合,在使用图卷积神经网络学习空间依赖过后使用门控循环单元学习时间依赖关系。

(5) STHGCN^[22]: STHGCN 结合历史的流量数据和图节点之间的拓扑关系构建超图,使用超图卷积和门控循环单元学习空间和时间的依赖关系。

(6) ASTGCRN^[13]: ASTGCRN 在 GCRN 的基础之上,使用注意力机制加强时间和空间关系的学习。

(7) DSTAGNN^[23]: DSTAGNN 是一种基于数据层面的特性来构建图结构的时空预测模型,通过学习不同研究单元之间时间序列的相似性来捕捉

空间依赖关系。

(8) HYGCN^[1]: HYGCN 采用图卷积和超图卷积分别学习低阶和高阶的空间依赖关系，并使用时间卷积网络学习时间依赖关系，是纯数据驱动的一种时空预测模型。

(9) PDGSTPM(基于POI序列的欧式距离表征先验):在该PDGSTPM的变体中,采用POI序列欧式距离度量的功能相似性作为先验,引导图注意力机制进行空间依赖建模,其余部分同PDGSTPM。

(10) PDGSTPM(基于POI序列的余弦距离表征先验):在该PDGSTPM的变体中,采用POI序列余弦距离度量的功能相似性作为先验,引导图注意力机制进行空间依赖建模,其余部分同PDGSTPM。

本研究采用均方根误差(RMSE)和平均绝对误差(Mean absolute error, MAE) 2项指标来评估模型的表现,其计算方法如下:

$$RMSE = \sqrt{\frac{\sum_j (\hat{y}_j - y_j)^2}{n}} \quad (9)$$

$$MAE = \frac{\sum_j |\hat{y}_j - y_j|}{n} \quad (10)$$

式中: \hat{y}_j 和 y_j 分别表示预测值和真实值; n 表示样本数。

3 实验结果与分析

3.1 研究区概况

本研究选取厦门岛作为研究区域。如图6所示,厦门岛内含思明区和湖里区2个行政区,是厦门市的中心城区所在地。岛内交通四通八达、人口数量较多,适宜开展有关城市居民活动强度的研究。本研究将厦门岛划分为633个500 m×500 m的格网。

3.2 数据来源及预处理

本研究所使用的城市居民活动强度提取自手




图6 厦门岛概况

Fig. 6 Overview of Xiamen Island

机定位数据。如表2所示,该数据包含脱敏id、经纬度信息和开始时间。本研究首先对手机定位数据进行去重、去除异常值、乒乓漂移清洗等预处理,再从0点开始,以15 min为一个时间步长来统计每个研究单元内不同的脱敏id数量作为居民活动强度。

本研究选择了2023年3月1日—28日的手机定位数据,为了使得训练集、测试集及验证集均包含工作日和周末,将3月1日—3月21日的数据作为训练集(从周三开始至周二结束),22日—25日作为验证集(从周三开始至周六结束),26日—28日作为测试集(从周日开始至周二结束)。在每个数据集中,本研究分别运用滑动窗口的方法将历史 L 个时间步的居民活动强度作为输入,未来 Q 个时间步作为输出。

3.3 与基线方法的预测精度对比分析

为了验证PDGSTPM的有效性,本研究对其和基线方法进行了对比实验,以单步预测和双步预测为例,其结果见表3。结果显示,PDGSTPM在2项指标上均取得最优表现,与所有的基线方法相比均有较为明显的提升。单步预测方面,DSTAGNN的RMSE最优,为22.26,相比于该方法,PDGSTPM的

表2 手机定位数据示例

Tab. 2 Example of mobile phone location data

脱敏ID	经度/°E	纬度/°N	开始时间
28d0b0e1-c457-4280-87d6-50808db94a ^{**}	117.58 ^{**}	26.231 ^{**}	2023/3/1 10:02
5a0908a1-5254-358a-aec7-ef065b8e3d ^{**}	118.56 ^{**}	24.821 ^{**}	2023/3/1 19:25
.....
80e7c41c-2e41-4f14-a76d-5ab48f8b10 ^{**}	109.40 ^{**}	24.343 ^{**}	2023/3/1 9:26

表3 与基线方法的比较

Tab. 3 Comparison with baseline methods

模型	单步预测		双步预测	
	RMSE	MAE	RMSE	MAE
LSTM	27.87	15.68	33.17	18.09
STHGCN	28.61	16.03	33.97	18.44
STGCN	26.54	15.38	26.68	15.34
ASTGCN	26.22	15.18	28.72	16.44
TGCN	26.66	14.97	32.76	17.86
ASTGCRN	27.97	15.74	33.29	18.11
DSTAGNN	<u>22.26</u>	14.63	<u>24.46</u>	15.41
HYGCN	24.24	<u>13.89</u>	28.08	15.36
PDGSTPM(基于POI序列 欧式距离表征先验)	24.60	14.06	26.46	<u>14.97</u>
PDGSTPM(基于POI序列 余弦距离表征先验)	24.65	14.14	26.93	15.27
PDGSTPM	21.55	12.63	23.09	13.50


注:下划线标注的数值为最优基线模型。

RMSE 降低了约 3.2%;而 HYGCN 的 *MAE* 最优,为 13.89,相比于该方法,PDGSTPM 的 *MAE* 降低了约 9.1%;基于 POI 序列欧式距离表征先验的 PDGSTPM 优于余弦距离表征先验,基于 POI 序列欧式距离表征先验 PDGSTPM 的 *RMSE* 和 *MAE* 分别为 24.60 和 14.06,相较于该方法,基于格网-城市功能多元关系表征先验的 PDGSTPM 两项指标分别降低了约 12.4% 和 10.2%。双步预测方面,DSTAGNN 的 *RMSE* 最优,为 24.46,相比于该方法,PDGSTPM 的 *RMSE* 降低了约 5.6%;而基于 POI 序列欧式距离表征先验 PDGSTPM 的 *MAE* 最优,为 14.97,PDGSTPM 的 *MAE* 相比于该方法降低了约


9.8%;基于 POI 序列欧式距离表征先验的 PDGSTPM 优于基于余弦距离表征先验,基于 POI 序列欧式距离表征先验 PDGSTPM 的 *RMSE* 为 26.46,相较于该方法,基于格网-城市功能多元关系表征先验 PDGSTPM 的 *RMSE* 指标降低约 12.7%。DSTAGNN 和 HYGCN 两者为数据驱动方法,并未使用 POI 挖掘格网之间的功能相似性作为先验。相比之下,本研究提出的使用多元功能相似性先验引导时空依赖建模这一创新性设计显著提升了复杂时空模式的学习能力。此外,基于 POI 序列距离提取先验的方法采用一阶对偶关系表征功能相似性,难以有效刻画格网与城市功能之间的多元关系,导致模型精度损失。实验结果有力地验证了本研究设计的先验引导框架在时空预测任务中的有效性。

3.4 超参数敏感性分析

为验证模型鲁棒性及参数选择的合理性,本研究针对 PDGSTPM 的主要超参数即输入的历史居民活动强度时间步数 L 、隐藏维度 h 、 λ_1 和 λ_2 展开敏感性分析。通过系统性地调整参数取值并观测模型的精度,探究不同超参数对模型性能的影响,以单步预测为例,结果如图 7 和图 8 所示。对于输入的历史时间步数,本研究将其设置为 7~12 依次递增,而隐藏维度设置为 32、64 一直到 1 024。研究发现,PDGSTPM 对输入的历史时间步数鲁棒性较强,在不同的输入步数下其 *RMSE* 变化幅度大约为 0.45,而对隐藏维度的鲁棒性较差, *RMSE* 的变化幅度约为 2.7。随着输入的历史时间步数增加,模型能够获取到的历史时间序列信息逐渐增多,



(a) 输入的历史时间步数



(b) 隐藏维度

图 7 历史时间步数和隐藏维度的敏感性分析

Fig. 7 Sensitivity analysis of historical timesteps and hidden dimensions




图8 λ_1 和 λ_2 的敏感性分析
Fig. 8 Sensitivity analysis of λ_1 and λ_2

RMSE 和 *MAE* 波动减小, 当历史时间步数为 9 时, 二者达到最小值, 当历史时间步数大于 9 时, 二者波动增加, 故本研究将输入的历史时间步数设置为 9。对于隐藏维度而言, 随着隐藏维度增加, 模型捕获潜在的复杂时空依赖特征的能力逐渐增强, *RMSE* 和 *MAE* 均波动下降, 当隐藏维度达到 512 时, 两者达到最小值。随着其继续增加, 模型学习到了一定的冗余特征, 故而 *RMSE* 和 *MAE* 相比于 512 维时出现了上升的现象。因此, 本研究将隐藏维度设置为 512 维。对于 λ_1 和 λ_2 这 2 个超参数, 由于其二者关乎互为补充的先验和数据引导构建, 故而本研究使用网格搜索法对其进行超参数敏感性分析, 将两者分别设置为 0.1、0.2、0.3 和 0.4。PDGSTPM 对 λ_1 和 λ_2 的鲁棒性介于输入历史时间步数和隐藏维度之间, 其 *RMSE* 的变化幅度为 1.22。从全局视角来看, 当 $\lambda_1=0.3, \lambda_2=0.1$ 时, *RMSE* 最小, 故本研究将 λ_1 设置为 0.3, λ_2 设置为 0.1。

3.5 消融实验

为了进一步验证 PDGSTPM 各模块的有效性, 本研究开展了消融实验, 依次消去先验引导和数据引导部分, 并观察模型的精度表现, 以单步预测为例, 其结果如表 4 所示。当消去先验引导的超图卷积时, *RMSE* 和 *MAE* 这 2 个指标相比于完整的模型分别上升了 2.35 和 1.15, 上升了约 10.9% 和 9.1%, 当消去数据引导的图注意力时 2 个指标分别上升了 0.93 和 0.55, 分别上升了约 4.3% 和 4.4%。结果证明, 2 种引导均对于模型精度的提升存在较大的贡献。相比于数据引导, 先验引导的作用更

加明显, 验证了基于高阶多元关系深入表征多元功能相似性作为先验信息, 引导复杂空间依赖建模的必要性, 同时也进一步印证了 PDGSTPM 优于数据驱动类的基线方法 DSTAGNN 和 HYGCN 的原因。

3.6 预测结果的定性分析

为了研究模型的可靠性和合理性, 本研究计算验证集工作日中 5 个时间段单步预测的绝对误差和基于表 1 中重分类后 POI 的香农熵, 并对其空间分布情况进行可视化。如图 9 所示, 从时间维度上看, 8:00—8:15、12:00—12:15 和 18:00—18:15 的最大误差均超过 170, 而 22:00—22:15 最大误差不超过 110, 2:30—2:45 的最大误差不超过 60。总体来看, 预测误差在夜间比白天小。柴宏博等^[24]对居民日常行为进行调查, 发现居民通常在 23:00 至次日 6:00 睡眠, 其余时间进行通勤、工作、娱乐等活动。相比于娱乐、通勤等活动, 居民睡眠活动发生的地点相对固定, 在此时间段的居民活动强度每天空间分布相对一致, 导致其预测难度低, 因而误差较小。从空间视角来看, 无论哪个时间段, 厦门岛北部的湖里区整体上的预测误差均高于南部的思明区, 这一现象的原因在于, 北部的人口总体上多于南部。Li 等^[12]指出较大的人口基数会导致复杂的居民流动和交互模式, 因而高人口地区的居民活动强度具有较高的不可预测性。此外, 图 9(a) 中 POI 香农熵的空间分布基本和预测误差的空间分布相吻合。Zhang 等^[25]发现若某区域含有办公区、住宅区、商业区等多种城市功能区域, 则该区域的居民活动具有多目的性, 因而难以预测其活动强度。相对而言, 功能单一的地区预测难度低。POI 的香农熵是城市功能混合程度的一种表征, 其值越大, 表示城市功能的混合程度越高^[26]。因此高香农熵的地区居民活动强度不可预测性更高, 其误差更大。以上分析证明 PDGSTPM 预测误差的时空分布基本和已有的研究相互印证, 证明模型具有一定的可靠性和合理性。

表 4 消融实验结果

Tab. 4 Ablation results

模型	RMSE	MAE
去掉先验引导的超图卷积	23.90	13.78
去掉数据引导的图注意力	22.48	13.18
完整的模型	21.55	12.63




图9 香农熵和不同时间段绝对误差的空间分布

Fig. 9 Spatial distributions of shannon entropy and absolute errors across different time periods

4 结论

对城市居民活动强度的精准预测对于智慧城市建设与居民生活质量的提升具有重要意义。然而,现有多数研究尚未充分利用先验知识来引导深度学习模型,尤其在建模混合城市功能格网间复杂空间依赖关系的方面存在不足。为解决这一问题,本研究提出了新颖的PDGSTPM。首先,该模型使用了面向城市功能语义的超边构建机制,利用自监督学习将POI表征的城市功能特性显式编码为可量化分析的高阶多元关联网络进而挖掘隐式表征的多元功能相似性先验,实现了城市格网空间依赖建模由一阶对偶关系向高阶多元关系的突破;其次,本研究利用一阶瓦瑟斯坦距离建立了历史观测数据的融合多粒度相似性度量方法,通过捕捉居民活动强度序列中的形态一致性挖掘历史观测数据中隐含的变化特性来进行数据层面的相似性表征,以实现数据层面相似性与功能相似性先验的互补;最后,使用前述挖掘的先验和数据层面的相似性对深度图神经网络进行引导,通过先验-数据双引导的图神经网络架构,PDGSTPM能够捕捉复杂的时空依赖关系,实现了预测精度的明显提升。

本研究使用2023年3月厦门市手机定位数据提取的城市居民活动强度进行了预测实验,结果表明,

相比于最优基线方法,PDGSTPM的RMSE和MAE 2项指标在单步预测方面分别降低了3.2%和9.1%,双步预测方面降低了5.6%和9.8%;本研究创新性引入的多元功能相似性先验对精度的提升作用尤为明显,当消去该先验引导的超图卷积运算时,2项指标在单步预测方面分别上升了10.9%和9.1%;模型预测误差的时空分布规律同已有的研究基本吻合,模型具有一定的科学性和可靠性^[12,25]。

本研究提出的时空预测模型在理论创新与实践应用2个层面均具有较为重要的意义与广泛的价值。理论层面,地理空间人工智能是将人工智能技术与时空数据深度融合的一种新兴研究范式,旨在高效处理和分析空间轨迹、POI等多源地理数据。本研究提出基于格网与城市功能之间多元关系提取先验知识,并用于引导空间依赖建模的新思路,实现了一阶对偶关系向高阶多元关系建模的突破,为地理空间人工智能的建模提供了全新视角。

实际层面,本模型除了预测城市居民活动强度外还可以对城市交通流进行预测。此外,所构建的超图模型同样具备良好的迁移性与拓展性。例如,在推荐系统中,可类比地利用超图来建模用户与商品之间复杂的多对多交互关系,进而实现更加精细的个性化推荐。此外,研究中使用的融合不同时间尺度进行数据层面相似性建模的机制,同样适用于

刻画其余具有多尺度特性的动态演化规律,如共享单车或者出租车需求变化、空气污染程度变化、城市能源消耗变化等,可以融合多尺度的时间信息进而完成预测和分析等任务。

然而,本研究依然存在3个方面的不足:①城市居民活动会受到天气、突发事件等外部因素的影响,而本研究尚未将这些因素纳入考虑来辅助进行时空预测;②由于数据集的局限性,本研究尚未能在不同季节或不同区域开展实验,以验证模型的鲁棒性和泛化性;③基于手机定位数据度量的城市居民活动强度存在一定偏差。在用户手机关机等情况下,手机定位数据会停止采样。这些不足也是未来研究中亟待改进的方向。

AI使用说明: 本文没有使用AI技术。

利益冲突: Conflicts of Interest

所有作者声明不存在利益冲突。

All authors disclose no relevant conflicts of interest.

作者贡献: Author Contributions

钟诚、吴升和王培晓负责研究框架和概念设计;钟诚、吴升和王培晓主笔初稿的撰写;钟诚和王培晓完成实验和图表绘制;张恒才、程诗奋、陆峰对初稿提出重要意见并参与文章的修改。所有作者均阅读并同意最终稿件的提交。

ZHONG Cheng, WU Sheng and WANG Peixiao were responsible for the research framework and conceptual design. They drafted the initial manuscript. ZHONG Cheng and WANG Peixiao conducted the experiments and prepared the figures and tables. ZHANG Hengcai, CHENG Shifen and LU Feng provided significant comments on the initial manuscript and contributed to the revision. All authors have read and approved the final version of the manuscript for submission.

参考文献(References):

- [1] Wang Y, Zhu D. A hypergraph-based hybrid graph convolutional network for intracity human activity intensity prediction and geographic relationship interpretation[J]. *Information Fusion*, 2024, 104: 102149. DOI:10.1016/j.infus.2023.102149
- [2] 赵鹏军,陈霄依,王祎勍,等.城市系统交通需求模拟预测技术框架构建及应用[J].*地球信息科学学报*,2025,27(3):539-552. [Zhao P J, Chen X Y, Wang Y Q, et al. Construction and application of an urban system-based travel demand forecasting technology framework[J]. *Journal of Geo-information Science*, 2025, 27(3): 539-552.] DOI:10.12082/dqxxkx.2024.240313
- [3] 张新长,华淑贞,齐霁,等.新型智慧城市建设与展望:基于AI的大数据、大模型与大算力[J].*地球信息科学学报*,2024,26(4):779-789. [Zhang X Z, Hua S Z, Qi J, et al. Progress and prospects of new smart city construction: AI-based big data, big models and big computing power[J]. *Journal of Geo-information Science*, 2024, 26(4): 779-789.] DOI:10.12082/dqxxkx.2024.240065
- [4] 赵子铭.基于ARIMA模型的中国人口预测[J].*赤峰学院学报(自然科学版)*,2019,35(9):10-12. [Zhao Z M. Population forecast of China based on the ARIMA model [J]. *Journal of Chifeng University*, 2019, 35(9): 10-12.] DOI:10.3969/j.issn.1673-260X.2019.09.005
- [5] 赵天伟,陈惠达.基于线性回归模型、马尔萨斯人口增长模型及logistic模型的全国人口预测[J].*广东医科大学学报*,2023,41(6):623-627. [Zhao T W, Chen H D. Population forecast nationwide based on linear regression model, Malthus Population Growth Model and logistic model [J]. *Journal of Guangdong Medical University*, 2023, 41(6):623-627.] DOI:10.3969/j.issn.1005-4057.2023.06.005
- [6] 高松.地理空间人工智能的近期研究总结与思考[J].*武汉大学学报(信息科学版)*,2020,45(12):1865-1874. [Gao S. A Review of Recent Researches and Reflections on Geospatial Artificial Intelligence[J]. *Geomatics and Information Science of Wuhan University*, 2020, 45(12): 1865-1874.] DOI:10.13203/j.whugis20200597
- [7] 王培晓,张恒才,张岩,等.地理空间智能预测研究进展与发展趋势[J].*地球信息科学学报*,2025,27(1):60-82. [Wang P X, Zhang H C, Zhang Y, et al. GeoAI-driven spatiotemporal poral prediction: Progress and prospects[J]. *Journal of Geo-information Science*, 2025, 27(1): 60-82.] DOI:10.12082/dqxxkx.2025.240718
- [8] Wang P, Zhang H, Cheng S, et al. A lightweight spatiotemporal graph dilated convolutional network for urban sensor state prediction[J]. *Sustainable Cities and Society*, 2024, 101: 105105. DOI:10.1016/j.scs.2023.105105
- [9] Wang P, Zhang H, Liu J, et al. Efficient inference of large-scale air quality using a lightweight ensemble predictor[J]. *International Journal of Geographical Information Science*, 2025, 39(4):900-924. DOI:10.1080/13658816.2024.2437044
- [10] 王培晓,张彤,聂士超,等.顾及缺失值的因果图时空预测网络[J].*测绘学报*,2023,52(5):818-830. [Wang P X, Zhang T, Nie S C, et al. A causal graph convolutional network considering missing values for spatio-temporal prediction[J]. *Acta Geodaetica et Cartographica Sinica*, 2023, 52(5): 818-830.] DOI:10.11947/j.AGCS.2023.20220021

- [11] 王培晓,张恒才,张彤,等.基于注意力常微分方程的PM2.5浓度预测及其可解释性分析[J].地球信息科学学报,2024,26(6):1363-1373. [Wang P X, Zhang H C, Zhang T, et al. An attentional ordinary differential equation for predicting PM2.5 concentration and its interpretability analysis[J]. Journal of Geo-information Science, 2024, 26(6): 1363-1373.] DOI:10.12082/dqxxkx.2024.230678
- [12] Li M, Gao S, Lu F, et al. Prediction of human activity intensity using the interactions in physical and social spaces through graph convolutional networks[J]. International Journal of Geographical Information Science, 2021, 35(12):2489-2516. DOI:10.1080/13658816.2021.1912347
- [13] Liu H, Zhu C, Zhang D, et al. Attention-based spatial-temporal graph convolutional recurrent networks for traffic forecasting[C]// Springer Nature Switzerland, 2023: 630-645. DOI:10.1007/978-3-031-46661-8_42
- [14] Li M, Gao S, Qiu P, et al. Fine-grained crowd distribution forecasting with multi-order spatial interactions using mobile phone data[J]. Transportation Research Part C: Emerging Technologies, 2022, 144:103908. DOI:10.1016/j.trc.2022.103908
- [15] 张彤,刘仁宇,王培晓,等.感知物理先验的机器学习及其在地理空间智能中的研究前景[J].地球信息科学学报,2023,25(7):1297-1311. [Zhang T, Liu R Y, Wang P X, et al. Physics-informed Machine Learning and Its Research Prospects in GeoAI[J]. Journal of Geo-information Science, 2023,25(7):1297-1311.] DOI:10.12082/dqxxkx.2023.220795
- [16] 莫怡晨,卢德格尔·霍夫施塔特,李飚,等. ArchIndex: 基于多源数据的城市街区检索引擎[J].新建筑,2024(1):15-21. [Mo Y C, Lu D G H F, Li B, et al. index: A web-based and data-driven retrieval system for city blocks[J]. New Architecture, 2024(1):15-21.] DOI:10.12069/j.na.202401015
- [17] Niu H, Silva E A. Delineating urban functional use from points of interest data with neural network embedding: A case study in greater london[J]. Computers, Environment and Urban Systems, 2021,88:101651. DOI:10.1016/j.compenvurbsys.2021.101651
- [18] 陈泽东,谯博文,张晶.基于居民出行特征的北京城市功能区识别与空间交互研究[J].地球信息科学学报,2018,20(3):291-301. [Chen Z D, Qiao B W, Zhang J. Identification and spatial interaction of urban functional regions in Beijing based on the characteristics of residents' traveling [J]. Journal of Geo-information Science, 2018,20(3):291-301.] DOI:10.12082/dqxxkx.2018.170531
- [19] 胡灵杰.基于POI数据和Doc2Vec模型的城市功能区识别和分析[J].城市建筑,2025,22(5):121-126. [Hu L J. Identification and analysis of urban functional areas based on POI data and Doc2Vec model[J]. Urban and Rural Planning and Design, 2025, 22(5): 121-126.] DOI:10.19892/j.cnki.csjz.2025.05.27
- [20] 韦烨娜,吴升.融合区域嵌入表示的城市功能区识别方法[J].地球信息科学学报,2025,27(2):424-440. [Wei Y N, Wu S. A Method for Identifying Urban Functional Regions by Integrating Regional Embedding Representations [J]. Journal of Geo-information Science, 2025,27(2):424-440.] DOI:10.12082/dqxxkx.2025.240484
- [21] 李伟梅,高雷阜.基于分数阶矩和分片Wasserstein距离的鲁棒风险度量优化模型[J].统计与决策,2024,40(9):55-60. [Li W M, Gao L F. Robust risk measurement optimization model based on fractional moment and piecewise wasserstein metric[J]. Statistics and Decision, 2024, 40(9):55-60.] DOI:10.13546/j.cnki.tjyjc.2024.09.009
- [22] Wang J, Zhang Y, Wei Y, et al. Metro passenger flow prediction via dynamic hypergraph convolution networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2021,22(12):7891-7903. DOI:10.1109/TITS.2021.3072743
- [23] Lan S, Ma Y, Huang W, et al. Dstagnn: Dynamic spatial-temporal aware graph neural network for traffic flow forecasting[C]// Proceedings of the 39th International Conference on Machine Learning, Baltimore, Maryland, USAPMLR, 2022:11906-11917
- [24] 柴宏博,冯健.基于家庭生命历程的北京郊区居民行为空间研究[J].地理科学进展,2016,35(12):1506-1516. [Chai H B, Feng J. Behavior space of suburban residents in Beijing based on family life course[J]. Progress in Geography, 2016,35(12):1506-1516.] DOI:10.18306/dlkxjz.2016.12.007
- [25] Zhang Y, Wu S, Zhao Z, et al. An urban crowd flow model integrating geographic characteristics[J]. Scientific Reports, 2023,13(1):1695. DOI:10.1038/s41598-023-29000-5
- [26] 师浩辰,赵渺希,陈佩谦.土地混合使用视角下的地块间兼容度测度——以湖南省湘潭市市辖区为例[J].热带地理,2021,41(4):746-759. [Shi H C, Zhao M X, Chen P Q. Measuring the functional compatibility of land from the perspective of land-use mix: A case study of Xiangtan[J]. Tropical Geography, 2021, 41(4): 746-759.] DOI:10.13284/j.cnki.rddl.003361

■ 本文图文责任编辑: 黄光玉 蒋树芳